



UNIVERSIDAD DE CUNDINAMARCA

Facultad de Ingeniería · Extensión Chía

Deforestación y Transformación del Territorio

Gestor: Ing. Edison Gustavo Cañon Varela

Creadores de Oportunidades:

Amy Tatiana Gelves

Danna Valentina Gonzalez

Nicolas Suarez Rativa

Asignatura: Minería de Datos

Programa: Ingeniería de Sistemas y Computación

Año: 2026



Objetivo

Implementar y verificar, mediante SQL Server Integration Services (SSIS), un proceso ETL que aplique sobre dataset_consolidado.csv las reglas de tratamiento definidas a partir del diagnóstico de calidad de la Etapa 2, cargando el resultado en una base de datos SQL Server (DeforestacionDW). El proceso se ejecuta en tres iteraciones para verificar que es correcto, ajustable a partir de lo encontrado en cada corrida, y que repetir el mismo lote no genera duplicados.

1. Diagnóstico inicial y reglas de tratamiento

El diagnóstico de calidad de la Etapa 2 (perfilamiento y métricas sobre dataset_consolidado.csv, 88.513 filas / 20 columnas) identificó duplicados exactos, categorías sin homologar en tres idiomas/formatos distintos (driver_dominante, departamento, municipio), agregados regionales mezclados en la columna país, y valores atípicos en cuatro variables numéricas — sin violaciones de rango (0 casos). Cada problema se traduce a continuación en una regla de tratamiento implementada como parte del Data Flow "Tratamiento_Calidad", indicando el campo afectado, la acción y el componente de SSIS que la ejecuta.

Problema	Campo(s)	Acción / Componente SSIS	Justificación
Variables núcleo vacías	nivel_analisis, pais, anio, id_registro, fuente_origen	Enviar a revisión. Conditional Split, rama Revision_CamposNucleo (primera en orden de evaluación).	Sin estas columnas no hay forma confiable de ubicar ni comparar el registro entre escalas; se aísla para revisión en vez de asumir un valor.
Duplicados exactos	19 columnas de negocio (= hash_clave)	Descartar el duplicado interno del archivo (Sort) y reconocer como 'ya existente' el que ya estaba cargado (Lookup por contenido).	Comparar por id_registro no sirve: dos ejecuciones pueden numerar distinto el mismo contenido (ver sección 6).
Formato inconsistente en departamento/municipio	departamento, municipio	Homologar a capitalización estándar + 2 casos especiales (Bogotá D.C., San Andrés y Providencia). Lookup + Union All (para no perder las filas sin coincidencia).	Replica la lógica ya validada en la Etapa 2, ahora como tabla de referencia reutilizable.

Problema	Campo(s)	Acción / Componente SSIS	Justificación
Categorías en inglés	driver_dominante	Homologar al español del diccionario de datos (7 categorías fijas). Lookup contra limpio.driver_homologado.	Diccionario de traducción fijo, no traducción automática, para garantizar coincidencia exacta con el dominio documentado.
Agregados regionales mezclados en país	pais	Marcar (no eliminar) con es_agregado_regional. Lookup contra limpio.países_agregados.	La fila sigue siendo útil como referencia internacional; lo que no puede pasar es que se compare como un país más sin quedar explícito.
Texto sin convertir a tipo real	anio + 9 variables numéricas	Data Conversion con FastParse, conservando NULL cuando el origen viene vacío.	Las reglas de rango y las banderas de atípico comparan valores numéricos, no texto.
Año fuera de 2001-2024	anio	Enviar a revisión. Conditional Split, rama Revision_RangoAnio.	Rango documentado en el diccionario de datos; fuera de él es error de captura.
Valores negativos	area_perdida_bosque_ha, emisiones_co2_mg, area_transformada_ha, num_focos_calor, frp_promedio, area_forestal_ha, deforestacion_anual_ha_owid	Enviar a revisión. Conditional Split, rama Revision_ValoresNegativos.	Son magnitudes físicas; un negativo solo puede ser error de captura o de unidad.
Porcentaje/confianza fuera de 0-100	porcentaje_area_forestal, confianza_promedio_focos	Enviar a revisión. Conditional Split, rama Revision_RangoPorcentaje.	La Etapa 2 no halló violaciones en el dataset real (0 casos); la regla queda activa como verificación permanente.
Valores atípicos	area_perdida_bosque_ha, emisiones_co2_mg, area_transformada_ha, num_focos_calor	Marcar con una bandera booleana por variable, sin eliminar la fila. Derived Column, umbral IQR fijo de la Etapa 2 por variable.	La fila sigue siendo utilizable; queda señalada para que un análisis posterior decida si la incluye.



2. Diseño del Control Flow y del Data Flow

2.1 Control Flow

El paquete Etapa3_Calidad.dtsx encadena cinco tareas. Iniciar_Lote (Execute SQL Task) crea el registro del nuevo lote en staging.control_iteraciones y recupera su lote_id. Vaciar_Staging (Execute SQL Task) trunca staging.deforestacion_raw para que cada ejecución parta de una zona de staging limpia el archivo original nunca se modifica, solo se vuelve a leer.

Cargar_Staging_Desde_Archivo (Data Flow Task) copia el CSV, sin transformar, a staging.deforestacion_raw. Tratamiento_Calidad (Data Flow Task) aplica todas las reglas de la sección 1. Actualizar_Contadores (Execute SQL Task) escribe en staging.control_iteraciones los conteos finales de recibidos/aceptados/duplicados/revisión/ya existentes de esa ejecución.




Figura 1. Control Flow de Etapa3_Calidad.dtsx.

2.2 Data Flow: Cargar Staging Desde Archivo

Tres componentes: el Flat File Source CN_Origen_Deforestacion lee dataset_consolidado.csv y NULL del origen conservados como NULL, ver sección 6); un Derived Column agrega la columna lote_id a cada fila para poder identificar de qué ejecución vino; y un OLE DB Destination la inserta en staging.deforestacion_raw, que es NVARCHAR en todas sus columnas para no perder ninguna fila por un error de formato antes de que el resto del paquete pueda revisarla.




Figura 2. Data Flow Cargar_Staging_Desde_Archivo.

2.3 Data Flow: Tratamiento_Calidad

Este es el Data Flow principal. Lee staging.deforestacion_raw, cuenta las filas recibidas (Row Count RC_Recibidos), convierte los tipos de texto a numérico/entero real (Data Conversion, con FastParse), elimina duplicados exactos del propio archivo (Sort, comparando las 19 columnas de negocio) y cuenta lo que queda (RC_TrasDedup). A partir de ahí homologa driver_dominante, departamento y municipio (cada uno: Lookup contra su tabla de referencia + Union All para no perder las filas sin coincidencia, que son la mayoría), marca los agregados regionales y los valores atípicos, y finalmente el Conditional Split Reglas_Validez separa el flujo: las filas con algún problema van, según el motivo, a uno de cinco Derived Column (uno por regla) que se unen en Union All Unificar_Revision antes de caer en OLE DB Destination Destino_Revision; las filas sin problemas continúan hacia el Lookup Verificar_YaCargado, que decide si son nuevas (Destino_Limpio) o ya estaban cargadas (no se insertan).




Figura 3. Data Flow Tratamiento_Calidad completo (vista de diseño previa al ajuste de la Iteración 2: el Lookup Verificar_YaCargado se reconfiguró después para comparar por contenido, ver sección 4.5 y 6).




Figura 4. Detalle del tramo inicial (Visual Studio, vista de diseño).



3. Configuración de los componentes

A continuación, la configuración de los componentes más relevantes del Data Flow Tratamiento_Calidad, en el orden en que procesan los datos.

3.1 OLE DB Source

Lee staging.deforestacion_raw con SQL directo. Se agregó ORDER BY id_registro durante la Iteración 2, al investigar el problema de idempotencia (ver sección 6), un orden de lectura determinístico era necesario, aunque no fue, por sí solo, suficiente para resolverlo.




Figura 5. OLE DB Source Editor — CN_SQL_DeforestacionDW Origen_Staging.

3.2 Data Conversion: Conversion_Tipos

Convierte anio a entero de 2 bytes (DT_I2, para coincidir con el SMALLINT del destino) y las 9 variables numéricas a DT_R8 (double). Las 12 columnas tienen la propiedad personalizada FastParse en verdadero (analizador de formato fijo, no sensible a la configuración regional de

Windows), y el Flat File Source tiene activado "Retain null values from the source as null values in the data flow column" sin ambas cosas, la conversión fallaba en prácticamente todas las filas (ver sección 6, error 1).




Figura 6. Data Conversion Transformation Editor — Conversion_Tipos.

3.3 Sort (Eliminar_Duplicados)

Ordena por las columnas de negocio (nivel_analisis, fuente_origen, pais, departamento, municipio, anio_conv, ...) con "Remove rows with duplicate sort values" activado: dos filas con el mismo contenido en todas esas columnas se cuentan como duplicado exacto y solo una continúa el flujo. Row Count RC_TrasDedup, comparado con RC_Recibidos, es el conteo de "registros_duplicados" que se guarda en staging.control_iteraciones.

3.4 Lookup + Union All (homologaciones)



Los tres Lookup de homologación (Homolog_Driver, Homolog_Departamento, Homolog_Municipio) están configurados en Full cache, conexión OLE DB, contra las tablas limpio.driver_homologado / limpio.departamentos_homologados / limpio.municipios_homologados. La mayoría de las filas no necesita homologación (por ejemplo, solo 17 de 88.513 municipios), así que "Specify how to handle rows with no matching entries" está en Redirect rows to no match output, y un Union All inmediatamente después junta el output con coincidencia y el de sin coincidencia antes del Derived Column que aplica el valor final (ISNULL(valor_homologado) ? valor_original : valor_homologado). La configuración original, con Fail component, se documenta como error 2 en la sección 6.




Figura 7. Derived Column Aplicar_Municipio_Homologado — expresión municipio_final.

3.5 Conditional Split (Reglas_Validez)

Cinco ramas mutuamente excluyentes, evaluadas en este orden (la primera condición que se cumple decide el destino de la fila):



- Revision_CamposNucleo: ISNULL(nivel_analisis), ISNULL(pais), ISNULL(anio_conv) ISNULL(id_registro), ISNULL(fuente_origen)
- Revision_RangoAnio: anio_conv < 2001, anio_conv > 2024
- Revision_RangoPorcentaje: porcentaje_area_forestal fuera de [0,100] o confianza_promedio_focos fuera de [0,100] (ignorando NULL)
- Revision_ValoresNegativos: cualquiera de las 7 variables de área/emisión/conteo es negativa (ignorando NULL)
- Motivo_Error_Conversion: rama alimentada por el Error Output de Data Conversion (filas que ni siquiera pudieron convertirse), ver sección 6.

Cada rama activada alimenta un Derived Column Motivo_* que redacta el texto de motivo correspondiente; todas convergen en Union All Unificar_Revision. Las filas que no activan ninguna rama siguen hacia el Lookup Verificar_YaCargado.

3.6 Execute SQL Task (Registrar_Error)

Registra en staging.log_errores el mensaje de error del paquete (System::ErrorDescription) cuando algún componente falla en tiempo de ejecución, para trazabilidad adicional a nivel de paquete (independiente de los registros de revisión, que son errores de calidad del dato, no del proceso).



Execute SQL Task Editor

Configure the properties required to run SQL statements and stored procedures using the selected connection.

General
Parameter Mapping
Result Set
Expressions

General	
Name	Execute SQL Task Registrar_Error
Description	Execute SQL Task
Options	
TimeOut	0
CodePage	1252
TypeConversionMode	Allowed
Result Set	
ResultSet	None
SQL Statement	
ConnectionType	OLE DB
Connection	CN_SQL_DeforestacionDW
SQLSourceType	Direct input
SQLStatement	INSERT INTO staging.log_errores (mensaje) VA
IsQueryStoredProcedure	False
BypassPrepare	True

Name
Specifies the name of the task.

Browse... Build Query... Parse Query

OK Cancel Help

Figura 8. Execute SQL Task Editor — Registrar_Error.

4. Evidencias de ejecución de las tres iteraciones

Cada iteración se apoya en el hallazgo de la anterior. Las cifras provienen de `staging.control_iteraciones` y de `limpio.deforestacion / revision.deforestacion_revision` (consultas en `sql/03_verificaciones.sql`).

4.1 Iteración 1: Carga inicial del dataset real

Primer intento (lote 1): el paquete corrió pero la conversión de tipos falló en las 88.513 filas (error de conversión -1071607681), así que las 88.513 fueron enviadas a revisión. Este resultado no se cuenta como Iteración 1 válida; es la evidencia del error 1 (sección 6).

ResultaMessages

id_registro	nivel_analisis	fuentes_origen	pas	es_agregado_regional	departamento	municipio	año	latitud	longitud	area_perdida_bosque_ha	area_perdida_bosque_ha_atipico	emisiones_co2_mg	emisiones_co2_mg_atipico	driver_dominante	area_transformada_ha	area_transformada_ha_atipico

Figura 9. Lote 1 fallo masivo de conversión, antes del fix.

Después de aplicar el fix de NULL + FastParse (error 1), el lote 4 fue la primera ejecución completa y correcta: 88.513 recibidos, 80.592 aceptados, 7.921 duplicados exactos dentro del propio archivo, 0 enviados a revisión consistente con que la Etapa 2 no encontró violaciones de rango en el dataset real. Una verificación inmediata por hash_clave, sin embargo, encontró 7 grupos de filas (14 registros) con contenido idéntico que el Sort no había reconocido como duplicado exacto entre sí:

Results Messages																
id_registro	nivel_analisis	fuerza_origen	pais	es_agregado_regional	departamento	municipio	anio	latitud	longitud	area_perdida_bosque_ha	area_perdida_bosque_ha_atipico	emisiones_co2_mg	emisiones_co2_mg_atipico	driver_dominante	area_transformada_f	
1	12	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
2	16	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
3	17	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
4	36	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
5	39	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
6	44	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
7	57	Global	FAO_SDG	Albania	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
8	64	Global	FAO_SDG	Albania	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL

motivo	cantidad
Error de conversión -1071607681	88513

lote_id	transaccion	fecha_registro	registros_recibidos	registros_aceptados	registros_aplicados	registros_revision	registros_ya_existentes
1	1	2026-09-27 18:08:27.473	88513	0	88513	88513	0
2	2	2026-09-27 18:56:50.590	0	0	0	0	0
3	1	2026-09-27 19:34:33.017	0	0	0	0	0
4	1	2026-09-27 19:44:33.177	88513	80592	7921	0	0

hash_clave	repeticiones
0x4E4F525F5A5C0B585C1C0B57D07A5F10E7429A03	2
0x4C3FF866417E12F9F9874CF12E18F58E24E250E0B778A6	2
0x27AE5D2AF232C5DB4009056D403222CF422BE01453C	2
0x79F84171895745E3DC66F28A8F8F10EE343CF556681	2
0x88037F724936D8E2721CC0210032797AFAC18694AC351	2
0x76B8E0B8E1006056F465446400025E715D3C7E8419	2
0x0304E0A668796339677967962CDBA7AC3F1466587A	2

Query executed successfully.

DESKTOP-VPI8TRF\MSSQLSERVER...DESKTOP-VPI8TRF\amysge...DeforestationDW00:00:0180.604 rods

Figura 10. Lote 4 (Iteración 1) y verificación de hash_clave inmediatamente después: 7 grupos duplicados detectados pese al Sort.

Este hallazgo que el Sort por sí solo no garantiza cero duplicados de contenido es el que motiva usar hash_clave (y no solo el Sort) como verificación de unicidad a partir de aquí, y se retoma directamente en la Iteración 2.

4.2 Iteración 2: Verificación de idempotencia (repetir el mismo lote)

Objetivo: volver a cargar el mismo dataset_consolidado.csv y comprobar que no se generan filas nuevas todo debería reconocerse como "ya existente". El primer intento (lote 5) no lo fue: debía aceptar 0 filas y aceptó 2.663.}

```

1 SELECT TOP 5 *
2 FROM staging.control_iteraciones
3 ORDER BY lote_id ASC;

```


lote_id	transaccion	fecha_registro	registros_recibidos	registros_aceptados	registros_aplicados	registros_revision	registros_ya_existentes
1	5	2026-09-27 20:10:00.963	88513	2663	7921	0	77929
2	4	2026-09-27 19:44:33.177	88513	80592	7921	0	0
3	3	2026-09-27 19:34:33.017	0	0	0	0	0
4	2	2026-09-27 18:56:50.590	0	0	0	0	0
5	1	2026-09-27 18:08:27.473	88513	0	88513	88513	0

Figura 11. control_iteraciones: lote 4 (carga original) seguido del lote 5 (repetición) — 2.663 filas aceptadas que no debían aceptarse.

```

1 SELECT hash_clave, COUNT(*) AS repeticiones
2 FROM Limpio_deforestacion
3 GROUP BY hash_clave
4 HAVING COUNT(*) > 1;

```

hash_clave	repeticiones
0x01A007C8D47D4867592CE055F6CE1617DDF5127E7C645A8	2
0x01A72F629A3C07096B8C8F59ACAD3120500D31BA5E3EF1	2
0x01C1D1E2B9F1104B8B1E1EAD0E3E747603555690A91	2
0x01F4C70C103115CD795681EA28024E14C6FF1F8A32B71	2
0x01927F3A36A481303F1FF84B5F13C00945895F277E5E7D1	2
0x01C8120FD4A37808843A4BA3E0BA9FE336A1FA1C2981103	2
0x0226D28CF53ED05F320C8E0148D9B541C4D72C77014F7	2
0x045F420F7B21CDASEC7A93C48A1DD78F7042F1318CA35	2
0x01E1E19E9A3329E7ECF12777888EC48E246259FCC261D	2
0x04E369F7E22E106F988FE7F90D05D049F7B7E35C39C20	2
0x0283736981843826118FFD7E5CCC4D0E31888CFC5147E03	2
0x0286F1E5918C31203C27626A8ECC98F420208A44F3F53D9	2
0x0001514C3F90E6DFF51F29CFFC278F3E494F1B6CFB73095	2
0x0227E8FD07AA963464F3AD0E8E8CB9A642C4B323846	2
0x024C2C0A88A8719FC7279EF3E83ECC7D6CD94728F748	2
0x04009365081C6AFD9F155A98E0202A4E9F41C07B171695	2
0x04A3E392869F89614E77A0224E582A78114E1C0B3384C	2
0x02C516C5104EBAE4322411F468F2D0178E735D2F94DE31	2
0x019874020FC0905F70C39F9184F0B33C33FFAD803508	2

Figura 12. Verificación por hash_clave tras el lote 5: numerosos grupos de contenido duplicado.

Diagnóstico: el Lookup Verificar_YaCargado comparaba por id_registro. Un primer intento de corrección (ordenar la fuente con ORDER BY id_registro, ver figura 5) no fue suficiente el lote 6 volvió a fallar (2.924 aceptadas):

```

1 SELECT TOP 5 *
2 FROM staging_control_iteraciones
3 ORDER BY lote_id DESC;

```

lote_id	iteracion	fecha_ejecucion	registros_recibidos	registros_aceptados	registros_duplicados	registros_revisión	registros_ya_existentes
6	2	2026-09-27 20:30:46.343	88513	2924	7921	0	77668
5	1	2026-09-27 20:10:00.963	88513	2663	7921	0	77929
4	1	2026-09-27 19:44:33.177	88513	80592	7921	0	0
3	1	2026-09-27 19:34:33.017	0	0	0	0	0
5	2	2026-09-27 18:56:50.590	0	0	0	0	0

Figura 13. Lote 6 el fix de ordenar el origen no resolvió el problema.



La causa raíz real: el componente Sort no garantiza elegir siempre la misma fila física dentro de un grupo de duplicados exactos entre una ejecución y otra (no es un "stable sort" para los empates de su propia clave), así que el "ganador" de cada grupo podía cambiar de corrida a corrida y el Lookup, comparando por id_registro, no lo reconocía. La corrección definitiva fue reconfigurar el Lookup para comparar por las columnas de negocio en vez de por id_registro (ver sección 6, error 5, y el detalle de las columnas auxiliares en el error 6). Tras aplicar el fix y limpiar los duplicados que habían quedado de los lotes 5 y 6 (sql/04_limpieza_duplicados_idempotencia.sql), el lote 7 confirmó la idempotencia:

id_registro	nivel_analisis	fuentes_origen	pais	es_agregado_regional	departamento	municipio	anio	latitud	longitud	area_perdida_bosque_ha	area_perdida_bosque_ha_atipico	emisiones_co2_mg	emisiones_co2_mg_atipico	driver_dominante	area_transformada_ha
12	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
14	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
17	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
36	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
37	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
41	Global	FAO_SDG+OWID	Africa	1	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
57	Global	FAO_SDG	Albania	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
61	Global	FAO_SDG	Albania	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL

lote_id	iteracion	fecha_ejecucion	registros_recibidos	registros_aceptados	registros_duplicados	registros_revision	registros_ya_existentes
1	1	2025-09-27 18:08:27.473	88513	0	88513	88513	0
2	1	2025-09-27 18:56:50.590	0	0	0	0	0
3	1	2025-09-27 19:34:33.017	0	0	0	0	0
4	1	2025-09-27 19:44:33.177	88513	80592	7921	0	0
5	1	2025-09-27 20:10:00.963	88513	2663	7921	0	77929
6	2	2025-09-27 20:30:46.343	88513	2924	7921	0	77668
7	2	2025-09-27 22:56:57.193	88513	0	7921	0	80592

hash_clave	repeticiones

Figura 14. Lote 7, después del fix: 0 aceptadas, 80.592 reconocidas como ya existentes, 0 grupos de hash_clave duplicado.

La sección 7 retoma esta evidencia en detalle, por ser el punto que la actividad pide verificar explícitamente.

4.3 Iteración 3 Dataset de prueba dirigido

El dataset real no tiene violaciones de rango, así que no permite demostrar las rutas de revisión. Se construyó un archivo sintético de 8 filas (pruebas_iteracion3/dataset_prueba_iteracion3.csv, fuente_origen='PRUEBA_QA', id_registro 900001-900008): dos filas que disparan homologación (una de ellas además con un valor atípico), cuatro filas una por cada rama del Conditional Split y una fila con el mismo contenido de negocio que una fila real ya cargada (id_registro=12) pero con un id_registro nuevo (900007), para reconfirmar con datos frescos que la comparación de idempotencia es por contenido y no por identificador. El primer intento (lote



8) falló por un detalle de formato del archivo (fin de línea LF en vez de CRLF, ver sección 6); corregido esto, el lote 9 dio el resultado esperado:

Results Messages																
id_registro	nivel_analisis	fuentes_origen	pais	es_agregado_regional	departamento	municipio	año	latitud	longitud	area_perdida_bosque_ha	area_perdida_bosque_ha_atpico	emisiones_co2_mg	emisiones_co2_mg_atpico	driver_dominante	area_transformada	
31	249	Global	FAO_SDG+OWID	Argentina	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
32	255	Global	FAO_SDG+OWID	Argentina	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
33	258	Global	FAO_SDG+OWID	Argentina	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
34	273	Global	FAO_SDG	América	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
35	278	Global	FAO_SDG	América	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
36	284	Global	FAO_SDG	América	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
37	298	Global	FAO_SDG	Aruba	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
38	302	Global	FAO_SDG	Aruba	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
39	306	Global	FAO_SDG	Aruba	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
4																
motivo		cantidad														
1	Error de conversión: -1071607681	88513														
2	Porcentaje o confianza fuera del rango 0-100	1														
3	Variable núcleo vacía [nivel_analisis/pais/año/...]	1														
4	Año fuera del rango 2001-2024	1														
5	Valor negativo en variable de área/emisión	1														
lote_id	iteracion	fecha_ejecucion	registros_recibidos	registros_aceptados	registros_duplicados	registros_revision	registros_ya_existentes									
2	2	1	2026-09-27 18:56:50.590	0	0	0	0	0								
3	3	1	2026-09-27 19:34:33.017	0	0	0	0	0								
4	4	1	2026-09-27 19:44:33.177	88513	80592	7921	0	0								
5	5	1	2026-09-27 20:10:00.963	88513	2663	7921	0	77929								
6	6	2	2026-09-27 20:30:46.343	88513	2924	7921	0	77668								
7	7	2	2026-09-27 22:36:57.193	88513	0	7921	0	80592								
8	8	2	2026-09-27 23:10:41.210	0	0	0	0	0								
9	9	2	2026-09-27 23:14:59.717	8	3	0	4	1								
hash_clave		repeticiones														
Query executed successfully.																
DESKTOP-VPIBT9R\MSSQLSERVER... DESKTOP-VPIBT9R\amyge... DeforestacionDW 00:00:01 80,602 rows																

Figura 15. Lote 9 (Iteración 3): 3 aceptadas, 4 en revisión (una por cada motivo), 1 reconocida como ya existente con un id_registro nunca antes visto.

Iteración	Lote(s) válido(s)	Recibidos	Aceptados	Duplicados	Revisión	Ya existentes
1 carga inicial	4	88.513	80.592	7.921	0	0
2 idempotencia	7 (tras corregir 5 y 6)	88.513	0	7.921	0	80.592
3 prueba dirigida	9 (tras corregir 8)	8	3	0	4	1



5. Manejo de errores y tratamiento de los registros en revisión

Los registros enviados a revisión no se descartan: `revision.deforestacion_revision` conserva `id_registro`, `valor_original`, `campo_afectado`, `motivo` y el `lote_id` que los generó, precisamente para que puedan auditarse y, si corresponde, corregirse y volver a intentarse en una carga posterior. A continuación, los errores técnicos reales encontrados construyendo y probando el paquete, con su diagnóstico y corrección.

Error 1: Conversión de tipos falla en prácticamente todas las filas (código -1071607681)

Diagnóstico: el Flat File Source no retenía los NULL del origen como NULL en el flujo (los convertía en cadena vacía) y Data Conversion no tenía FastParse activado. Corrección: se activó "Retain null values from the source as null values in the data flow column" en el Connection Manager y FastParse=True en las 12 columnas convertidas.

Error 2: Lookup Homolog_Municipio falla el componente completo ("Row yielded no match during lookup")

Diagnóstico: solo 17 de 88.513 municipios necesitan homologación; el resto, correctamente, no tiene coincidencia pero "Specify how to handle rows with no matching entries" estaba en Fail component.




Figura 16. Lookup Transformation Editor — configuración original (Fail component).




Figura 17. Data Flow original: el Lookup alimentaba directamente al Derived Column, sin separar match / no match.

Corrección: se cambió a Redirect rows to no match output y se agregó un Union All para juntar ambos outputs antes de continuar:




Figura 18. Conectando el Union All Unir_Municipios a los dos outputs del Lookup.

Error 3 : Execute SQL Task Registrar_Error: fallo extrayendo el resultado a DBTYPE_I4

Diagnóstico: el parámetro de entrada (el mensaje de error, un texto) tenía Data Type = LONG en vez de un tipo de texto.

Variable Name	Direction	Data Type	Parameter ...	Parameter ...
System::ErrorDe...	Input	LONG	0	-1



Corrección: se cambió el Data Type del parámetro a un tipo de text(VARCHAR/NVARCHAR) en la pestaña Parameter Mapping.

Error 4: Violación de restricción NOT NULL en las columnas,atípico al insertar en limpio.deforestacion

Diagnóstico: la lógica de tres valores de SSIS condicion ? a : b evalúa NULL cuando la condición involucra una comparación con un valor NULL, y no todas las filas tienen todas las variables numéricas. Corrección: se envolvió cada expresión de bandera atípica con ISNULL(valor) ? (DT_BOOL)0 : (valor > umbral ? (DT_BOOL)1 : (DT_BOOL)0) para las 4 variables marcadas.

Error 5: El paquete no era idempotente (desarrollado en la sección 4.2)

Diagnóstico: Lookup Verificar_YaCargado comparando por id_registro + Sort sin desempate estable entre ejecuciones. Corrección: reconfigurar el Lookup para comparar por columnas de negocio; documentado también en sql/04_limpieza_duplicados_idempotencia.sql.

Error 6 : El editor "Create Relationships" del Lookup no ofrece anio / anio_conv como pareja

Diagnóstico: el editor filtra el desplegable por coincidencia exacta de tipo de dato, no por tipos "compatibles": anio_conv (entero de 4 bytes en ese momento) no empareja con anio (SMALLINT / entero de 2 bytes).






Figura 20. Create Relationships: anio_conv no aparece como opción de entrada.




Input Column	Lookup Column
nivel_analisis	nivel_analisis
fuentes_origen	fuentes_origen
pais	pais
departamento_final	departamento
municipio_final	municipio
anio_conv	

Figura 21. A la inversa: con anio_conv ya en la lista, anio no aparece del lado del Lookup.



Input Column	Lookup Column
nivel_analisis	nivel_analisis
fuentes_origen	fuentes_origen
pais	pais
departamento_final	departamento
municipio_final	municipio
anio_conv	id_registro

Figura 22. El desplegable de entrada, frente a la columna anio del Lookup, solo ofrece id_registro.



Input Column	Lookup Column
nivel_analisis	nivel_analisis
fuentes_origen	fuentes_origen
pais	pais
departamento_final	departamento
municipio_final	municipio
anio_conv	anio

Figura 23. Y frente a anio_conv como entrada, el desplegable de columnas del Lookup aparece vacío.



Cambiar el tipo directamente en Data Conversion no era viable: anio_conv es una columna de paso usada por varios componentes Union All en distintas ramas del flujo, cada uno con su propio metadato de diseño cacheado cambiar el tipo en un solo lugar rompía a los demás ("metadata... does not match... Failed to set property OutputColumnLineageID"). Corrección definitiva: se agregó un Derived Column dedicado (Match_Lookup) justo antes del Lookup Verificar_YaCargado, con una columna nueva por cada campo que lo necesitaba, convertida al tipo exacto requerido (por ejemplo (DT_I2)anio_conv, (DT_NUMERIC,18,2)area_perdida_bosque_ha_conv), sin tocar ninguna columna usada por el resto del flujo.

Error 7 : "The FastParse custom property... cannot be set to true"

Diagnóstico: al intentar ajustar el tipo de las columnas decimales en Data Conversion (mismo enfoque del error 6), FastParse solo es válido para tipos enteros y de fecha/hora, no para DT_NUMERIC ni DT_R8 — y esas columnas ya tenían FastParse=True activado desde el error 1.




Figura 24. Mensaje de error: FastParse no es compatible con el tipo de dato elegido.

Corrección: se abandonó el intento de cambiar tipos en Data Conversion; el emparejamiento para el Lookup se resolvió por completo en el Derived Column Match_Lookup del error 6, dejando Data Conversion sin tocar.

Error 8: dataset_prueba_iteracion3.csv se cargó con 0 filas

Diagnóstico: el mensaje "the end of the data file was reached while reading header rows" señaló que el archivo se había generado con fin de línea Unix (LF), mientras que el Connection Manager está configurado para el delimitador de fila {CR} {LF} del dataset real. Corrección: se convirtió el archivo a fin de línea {CR} {LF}.



Tratamiento de los registros en revisión

Las 4 filas de revisión de la Iteración 3 ilustran cada motivo por separado:

id_registro	Campo / valor	Motivo registrado
900003	anio = 1995	Año fuera del rango 2001-2024
900004	area_perdida_bosque_ha = -50	Valor negativo en variable de área/emisión
900005	porcentaje_area_forestal = 120	Porcentaje o confianza fuera del rango 0-100
900006	pais = (vacío)	Variable núcleo vacía (nivel_analisis/pais/anio/...)

6. Comparación de resultados

Indicadores de calidad, dataset original (Etapa 2, sin tratar) contra el resultado final de la Iteración 1 en SSIS:

Indicador	Antes (Etapa 2)	Después (Etapa 3, SSIS)	Diferencia
Filas totales	88.513	80.585 (limpio.deforestacion, tras la verificación por hash)	-7.928
Duplicados exactos	7.928 (8,96%)	0 (Sort + verificación por hash de contenido)	-7.928
Variantes de 'departamento'	44	Homologadas vía Lookup a 11 valores de referencia	sin pérdida de categorías
Municipios en mayúscula sostenida	147	Homologados vía Lookup a 17 valores de referencia	sin pérdida de categorías
Categorías de driver_dominante	7, en inglés	7, homologadas al español vía Lookup	sin pérdida de categorías
Violaciones de rango (dataset real)	0	0 (verificado; forzado con datos sintéticos en la Iteración 3)	sin cambio, regla activa
Repetir el mismo lote	no evaluado (proceso no repetible)	0 filas nuevas (Iteración 2)	idempotencia añadida

El total de 80.585 filas (después de la verificación por hash de contenido, sección 4.1) coincide casi exactamente con el resultado independiente que ya había obtenido la Etapa 2 en Python (80.585 filas también) una validación cruzada entre dos implementaciones distintas del mismo criterio de deduplicación.

6.1 Ejemplos concretos, datos reales

Tomados directamente del dataset real cargado en la Iteración 1: homologación de 4 valores de 'departamento' (incluye ambos casos especiales) y una fila real marcada como atípica (id_registro=1491, area_perdida_bosque_ha=424.642 ha, muy por encima del umbral de 366,5 ha de la Etapa 2):



id_registro	pais	departamento	municipio	anio	area_perdida_bosque_ha	area_perdida_bosque_ha_atipico
1	Colombia	AMAZONAS	NULL	2017	424642.00	1
2	Colombia	ANTIOQUIA	NULL	2017	424642.00	1
3	Colombia	ARCHIPIELAGO DE SAN ANDRES, PROVIDENCIA Y SANTA C.	NULL	2017	424642.00	1
4	Colombia	Bogotá D.C.	NULL	2017	424642.00	1
5	Colombia	AMAZONAS	NULL	2017	424642.00	1
6	Colombia	ANTIOQUIA	NULL	2017	424642.00	1

Figura 25. Homologación de departamento (4 ejemplos reales) y una fila real marcada como atípica.

6.2 Ejemplos concretos, dataset de prueba (Iteración 3)

De izquierda a derecha: total de filas en limpio.deforestacion tras la Iteración 3 ($80.588 = 80.585 + 3$ aceptadas), homologación de departamento y driver_dominante (id_registro 900001), valor atípico marcado (id_registro 900002), motivo de cada fila enviada a revisión, y confirmación de que el duplicado por contenido (id_registro 900007) no se insertó:

total_limpio

80588

id_registro

900001

pais

Colombia

departamento

Bogotá D.C.

driver_dominante

Silvicultura

id_registro

900002

departamento

CUNDINAMARCA

municipio

CHÍA

area_perdida_bosque_ha

500.00

area_perdida_bosque_ha_atipico

1

id_registro

900003

motivo

Anio fuera del rango 2001-2024

900004

Valor negativo en variable de area/emision

900005

Porcentaje o confianza fuera del rango 0-100

900006

Variable nucleo vacia (nivel_analisis/pais/anio/...

deberia_ser_cero

0

Query executed successfully.

DESKTOP-VPIBT9R\MSSQLSERVER...

DESKTOP-VPIBT9R\myge...

DeforestacionDW

00:00:00

8 rows

Figura 26. Ejemplos antes/después con el dataset de prueba de la Iteración 3.

Evidencia adicional del hallazgo de la sección 4.1: justo antes de la corrección de idempotencia, el conteo de filas de limpio.deforestacion (83.255) reflejaba las 2.663 filas indebidamente aceptadas por el lote 5 sobre los 80.592 originales:

1	SELECT COUNT(*) AS total_filas FROM limpio.deforestacion
total_filas	83255

100% No issues found

Results Messages

1 total_filas 83255

Figura 27. COUNT(*) de limpio.deforestacion tras el lote 5 fallido: $83.255 = 80.592 + 2.663$.



7. Evidencia de que repetir el mismo lote no genera duplicados

Esta sección reúne, en un solo lugar, la evidencia de idempotencia desarrollada en la Iteración 2 (sección 4.2), porque la actividad pide verificarla explícitamente.

Causa raíz

El Lookup de idempotencia comparaba por id_registro. El componente Sort que elimina duplicados exactos no garantiza elegir siempre la misma fila física dentro de un grupo de duplicados entre una ejecución y otra (no es un 'stable sort' para los empates de su propia clave), incluso con el origen ordenado explícitamente (ORDER BY id_registro). El 'ganador' de cada grupo podía cambiar de corrida a corrida, y el Lookup no lo reconocía como ya cargado.

Corrección

Se reconfiguró el Lookup Verificar_YaCargado para comparar por las columnas de negocio (las mismas que arman hash_clave) en vez de por id_registro, usando columnas auxiliares del tipo exacto requerido (Derived Column Match_Lookup, sección 6 error 6 del informe).

Antes y después

	Lote	Aceptados	Ya existentes	Grupos de hash_clave repetido
Antes del fix	5	2.663 (debía ser 0)	77.929	varios grupos
Después del fix	7	0	80.592	0

Consulta de verificación (sql/03_verificaciones.sql), ejecutada antes y después:

```
SELECT hash_clave, COUNT(*) AS repeticiones FROM limpio.deforestacion GROUP BY hash_clave HAVING COUNT(*) > 1; -- 0 filas, después del fix
```

id_registro	nivel_analisis	fuerza_origen	pais	es_agregado_regional	departamento	municipio	anio	latitud	longitud	area_perdida_bosque_ha	area_perdida_bosque_ha_atipico	emisiones_co2_mg	emisiones_co2_mg_atipico	driver_dominante	area_transformada_j
12	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
14	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
17	Global	FAO_SDG	Afghanistan	0	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
36	Global	FAO_SDG+QWID	Africa	1	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
37	Global	FAO_SDG+QWID	Africa	1	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL
41	Global	FAO_SDG+QWID	Africa	1	NULL	NULL	2020	NULL	NULL	NULL	0	NULL	0	NULL	NULL
57	Global	FAO_SDG	Albania	0	NULL	NULL	2010	NULL	NULL	NULL	0	NULL	0	NULL	NULL
61	Global	FAO_SDG	Albania	0	NULL	NULL	2015	NULL	NULL	NULL	0	NULL	0	NULL	NULL

motivo	cantidad
Error de conversión: -1071607681	88513

lote_id	iteracion	fecha_ejecucion	registros_recibidos	registros_aceptados	registros_duplicados	registros_revision	registros_ya_existentes
1	1	2025-09-27 18:08:27.473	88513	0	88513	88513	0
2	1	2025-09-27 18:56:50.590	0	0	0	0	0
3	1	2025-09-27 19:34:33.017	0	0	0	0	0
4	1	2025-09-27 19:44:33.177	88513	80592	7921	0	0
5	1	2025-09-27 20:10:00.963	88513	2663	7921	0	77929
6	2	2025-09-27 20:30:46.343	88513	2924	7921	0	77668
7	2	2025-09-27 22:56:57.193	88513	0	7921	0	80592

hash_clave	repeticiones
------------	--------------

Figura 28. Lote 7: 0 aceptadas, 80.592 ya existentes, 0 grupos de hash_clave repetido.



Reconfirmación con datos frescos (Iteración 3): la fila 900007 repite la misma prueba con un id_registro nunca antes visto y contenido idéntico a una fila real ya cargada (id_registro=12).
Resultado: 0 aceptados, 1 reconocida como ya existente — confirma que la comparación es por contenido, no por identificador.



8. Enlaces

Recurso	Enlace
Repositorio (GitHub)	https://github.com/amis64/Deforestacion
Video de demostración	https://youtu.be/D1awrq_rLic