UNIVERSIDAD DE CUNDINAMARCA

Facultad de Ingeniería · Extensión Chía

Deforestación y Transformación del Territorio

Etapa 6 – Conocimiento Oculto

Gestor: Ing. Edison Gustavo Cañon Varela

Creadores de Oportunidades:

Amy Tatiana Gelves Espinosa
Danna Valentina Gonzalez Aldana
Nicolas Suarez Rativa

Asignatura: Minería de Datos – 901N

Programa: Ingeniería de Sistemas y Computación
Año: 2026

1. Contexto, Objetivo y Preguntas de Análisis

Elemento	Descripción
Contexto	El proyecto estudia la deforestación y la transformación del territorio en Colombia. Las Etapas 1 a 3 construyeron y depuraron el dataset (deforestacion_limpio.csv), la Etapa 4 mostró los conocimientos evidentes en tableros de Power BI y la Etapa 5 organizó los datos en un modelo estrella para analizarlos de forma multidimensional.
Objetivo de la Etapa 6	Descubrir patrones y relaciones que no son evidentes en los análisis descriptivos ni multidimensionales, mediante modelos supervisados y no supervisados en Orange Data Mining, y complementarlos con lo que dicen quienes comentan videos sobre el tema en YouTube.
Pregunta supervisada	Con lo que se sabe de un municipio hasta el año anterior (pérdida de los últimos años, área transformada, focos de calor, ubicación y causa dominante), ¿su pérdida de bosque de este año será **alta**? Alta significa pérdida de 129 ha o más (percentil 75 de 2004–2018). Es una clasificación binaria (Alta / No alta).
Pregunta de clustering	¿Existen perfiles de municipios según cuánto pierden, con qué persistencia y evolución reciente, y cuánto fuego y transformación agropecuaria los acompañan? No se usa la clase del modelo supervisado.
Pregunta de comentarios	¿Qué causas, responsables y propuestas mencionan quienes comentan videos sobre deforestación en Colombia, y cómo se compara con los datos?

Las tres preguntas se cruzan en la sección 8: el modelo supervisado dice qué se puede anticipar, el clustering agrupa los municipios y los comentarios aportan la voz de quienes opinan.

2. Descripción de los Datos y Transformaciones Realizadas

Se parte del mismo deforestacion_limpio.csv de las etapas anteriores (80.585 registros, 25 columnas); sus fuentes originales son Global Forest Watch, MapBiomas Colombia, NASA FIRMS, FAO y Our World in Data, con la capa de municipios del DANE. La preparación está en el script conocimiento_oculto/preparar_datos_orange.py y, dentro del flujo de Orange, en los widgets Select Rows, Group By y Python Script (sección 3).

Transformación	Motivo
Solo registros de nivel municipal (se quitan agregados regionales, nacionales y globales)	Las filas agregadas repetirían la pérdida de sus municipios. Quedan 77.245 filas regionales.

Transformación	Motivo
Una fila por municipio-año (Group By: promedio de área perdida y transformada, focos y coordenadas; primer valor de la causa dominante)	El dataset trae hasta tres filas casi idénticas por municipio-año (escala y fuente). Si no se agrupan, quedan «gemelas» en entrenamiento y prueba y las métricas salen infladas. Resultan 28.800 municipio-años.
Rezagos: pérdida del año anterior (t-1), de hace dos años (t-2), promedio de los tres años previos, tendencia (t-1 menos t-2), área transformada y su cambio, focos de calor (t-1)	El modelo solo puede usar lo que se sabía antes del año que se predice.
Clase «Alta» = pérdida del año ≥ 129 ha (percentil 75 calculado solo con 2004–2018)	El umbral se fija con el entrenamiento para no mirar el futuro. Es una definición propia del ejercicio: otro umbral cambia el problema.
Partición temporal: entrenamiento 2004–2018, prueba 2019–2024	Se entrena con el pasado y se evalúa con un futuro que el modelo no vio. Una validación cruzada aleatoria mezclaría años y daría resultados más optimistas (en Python, con el bosque aleatorio, la validación aleatoria de 5 pliegues da F1 de la clase Alta 0,817 frente a 0,852 en la prueba temporal; no es más optimista, pero la temporal es la que corresponde al uso real: anticipar años futuros).
Para el clustering: un renglón por municipio con 7 variables de perfil (2004–2024) y al menos 10 años de dato	Resume la trayectoria y deja 1.119 municipios.
Imputación con el promedio y estandarización (clustering); imputación dentro de cada modelo (supervisado)	Faltan datos de área transformada (7 % de las filas) y de focos de calor (61 %, solo existen 2012–2022). K-means usa distancia euclidiana y necesita variables en la misma escala.

Archivo para Orange	Filas	Contenido
conocimiento_oculto/datos/datos_supervisado.csv	23.499	Municipio-año con las 10 variables, la clase y la partición (se genera con preparar_datos_orange.py; en Orange lo produce el widget Python Script con script_supervisado.py).
conocimiento_oculto/datos/datos_clustering.csv	1.119	Municipio con las 7 variables de perfil (equivale al widget Python Script con script_clustering.py).
conocimiento_oculto/youtube/comentarios_limpios.csv	117	Comentarios de YouTube sin duplicados, vacíos ni ruido, con el texto anonimizado.

3. Flujo de Orange, Widgets, Conexiones y Parámetros

El trabajo en Orange (versión 3.36 o superior, con el complemento Text) es **un solo flujo** de 39 widgets organizado en cuatro bloques: preparación, modelos supervisados, clustering y comentarios. El archivo es conocimiento_oculto/conocimiento_oculto.ows y la guía paso a paso, orange/GUIA_FLUJOS_ORANGE.md. Los widgets Python Script usan conocimiento_oculto/orange_scripts/.

3.1 Preparación y modelos supervisados

Widget	Conexión	Parámetros	Para qué
File · Dataset tratado	→ Select Rows	deforestacion_limpio.csv	Cargar los datos
Select Rows · Solo municipios	→ Group By	nivel_analisis = Regional y es_agregado_regional = False	Quitar agregados
Group By · municipio-año	→ Python Script (×2)	Agrupar por departamento, municipio y año; promedios y primer valor de la causa	Una fila por municipio-año
Python Script · Rezagos y clase	→ Select Columns	script_supervisado.py: rezagos, umbral P75 de 2004–2018, clase_perdida, particion	Variables sin fuga y clase objetivo
Select Columns · Roles	→ Select Rows (×2), Distributions	Objetivo: clase_perdida. 10 predictoras. Meta: departamento, municipio, año, partición, pérdida del año	Definir roles
Select Rows · Entrenamiento / Prueba	→ modelos / → Test and Score	partición = Entrenamiento (≤ 2018) / Prueba (≥ 2019)	Partición temporal
Distributions · Balance de clases	← Select Columns	clase_perdida	Mostrar el desbalance
Logistic Regression	→ Test and Score	Ridge (L2), C = 1	Modelo 1
Tree	→ Test and Score, Tree Viewer	Árbol binario; mínimo 50 por hoja; no dividir con menos de 100; profundidad máxima 5; detener con 95 % de mayoría	Modelo 2
Random Forest	→ Test and Score	200 árboles; no dividir con menos de 10; semilla fija	Modelo 3
Test and Score · prueba temporal	→ Confusion Matrix, ROC Analysis	Test on test data; clase objetivo Alta	Evaluar los tres con la misma prueba
Confusion Matrix / ROC Analysis	← Test and Score	Clase Alta	Errores y curvas
Data Table · Coeficientes	← Logistic Regression	Salida Coefficients	Variables que más pesan

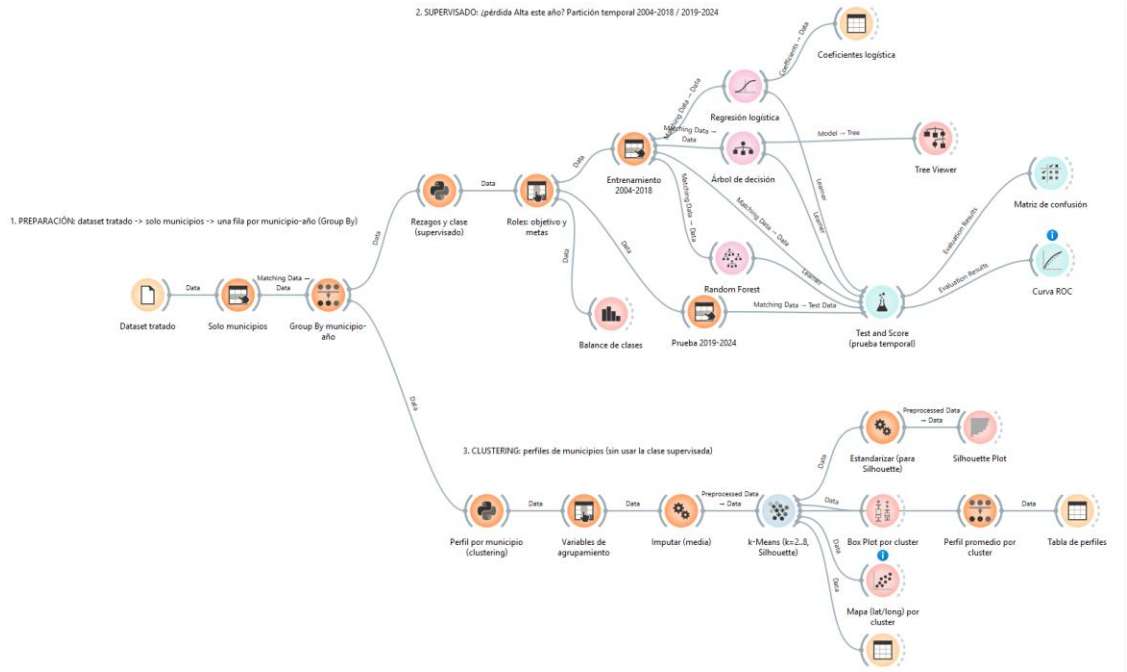


Figura 1. Bloques de preparación, modelos supervisados y clustering del flujo de Orange.

Del dataset tratado a una fila por municipio-año, la partición temporal y los tres modelos conectados a Test and Score. El bloque de clustering (abajo) se amplía en la Figura 2.

3.2 Clustering

Widget	Conexión	Parámetros	Para qué
Python Script · Perfil por municipio	← Group By → Select Columns	script_clustering.py: una fila por municipio con 7 variables	Resumir 2004–2024
Select Columns · Variables	→ Preprocess	7 variables sin objetivo; meta: departamento, municipio, latitud, longitud, años con datos	Definir variables
Preprocess · Imputar (media)	→ k-Means	Impute Missing Values: promedio	Rellenar faltantes
k-Means	→ Preprocess, Box Plot, Scatter Plot, Data Table, Group By	k de 2 a 8; k-means++; 10 repeticiones; 300 iteraciones; normalizar columnas	Agrupar y comparar k
Preprocess · Estandarizar	→ Silhouette Plot	Standardize a μ = 0, σ = 1	Calcular la silueta en la misma escala
Silhouette Plot / Box Plot / Scatter Plot	← k-Means	Agrupar por Cluster; mapa con longitud y latitud	Calidad y perfil

Widget	Conexión	Parámetros	Para qué
Group By · Perfil promedio	→ Data Table	Por Cluster: media de las 7 variables y conteo	Tabla de perfiles

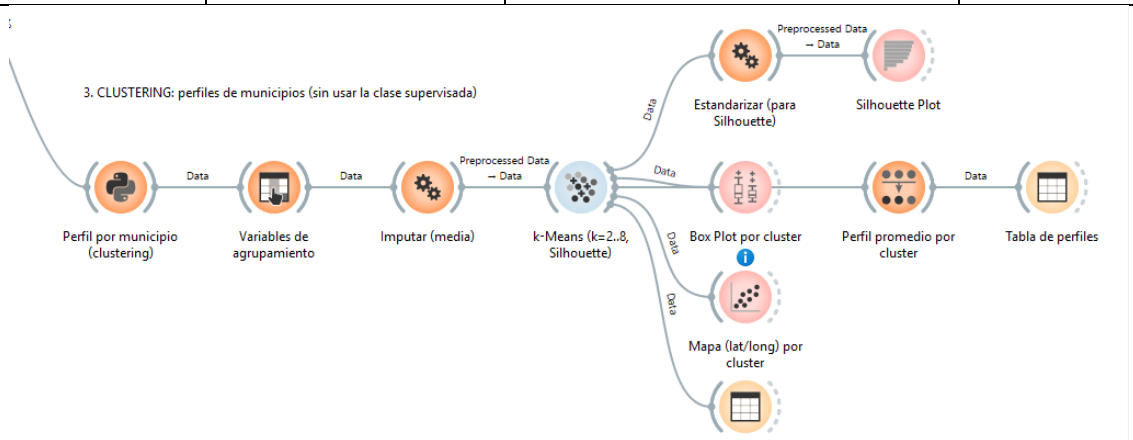


Figura 2. Bloque de clustering del flujo de Orange (detalle de la Figura 1).

Perfil por municipio, imputación, k-means de 2 a 8 grupos y widgets de interpretación.

3.3 Comentarios de YouTube

Widget	Conexión	Parámetros	Para qué
File · Archivo comentarios limpios → Corpus	→ Preprocess Text	comentarios_limpios.csv; idioma español; texto: texto	Cargar el corpus
Preprocess Text · español	→ Bag of Words, Topic Modelling	Minúsculas, sin acentos, sin URL; tokenización \w+; lematizador en español; palabras vacías en español, sin números y frecuencia de documento absoluta de 3 a 100, en ese orden (resultado: 516 tokens y 78 términos distintos en 117 comentarios)	Normalizar
Bag of Words · TF-IDF	→ Distances, Word Enrichment	Conteo, IDF, regularización L2	Matriz de términos
Topic Modelling · LDA	→ Word Cloud, LDAvis, Corpus Viewer	LDA, 5 temas	Temas
Word Cloud · LDAvis · Corpus Viewer	← Topic Modelling	Tema seleccionado; búsqueda de términos clave	Visualizar y citar evidencia

Widget	Conexión	Parámetros	Para qué
Distances → Hierarchical Clustering → Select Rows → Word Enrichment	← Bag of Words	Distancia coseno; enlace Ward; corte en 4 grupos (Top N); Select Rows elige un grupo; grupo contra el resto	Agrupar comentarios y caracterizarlos

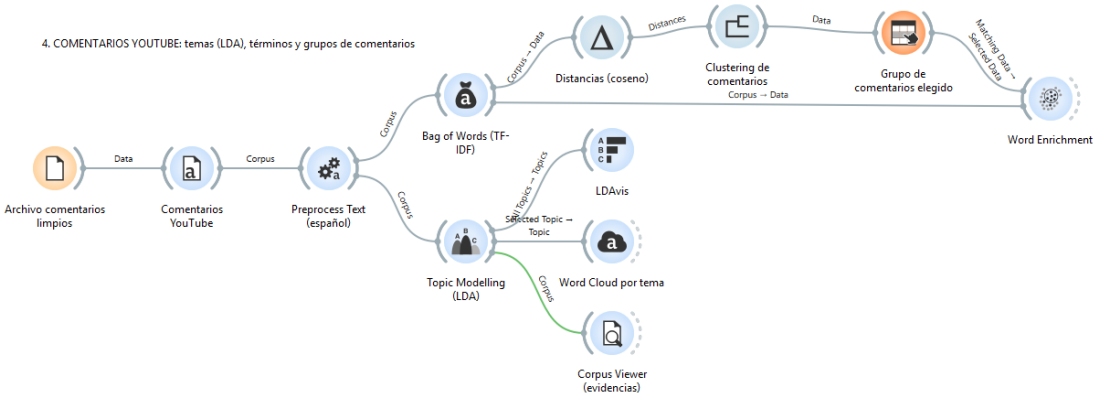


Figura 3. Bloque de análisis de texto del flujo de Orange.

Corpus, preprocesamiento, matriz TF-IDF, temas LDA y agrupación jerárquica.

4. Modelos Supervisados: Implementación, Evaluación y Comparación

4.1 Pregunta, tipo de problema y variables

Es un problema de clasificación binaria: la clase «Alta» (pérdida de 129 ha o más en el año) frente a «No alta»; no se predice una cantidad continua. Hay 23.499 municipio-años de 1.119 municipios: 16.785 para entrenamiento (2004–2018) y 6.714 para prueba (2019–2024).

Variable	Descripción	Faltantes
perdida_t1	pérdida del año anterior (numérica)	0,0 %
perdida_t2	pérdida de hace 2 años (numérica)	0,0 %
perdida_media_3a	promedio de los 3 años previos (numérica)	0,0 %
tendencia_perdida_t1	tendencia (t-1 menos t-2) (numérica)	0,0 %
area_transformada_t1	área transformada (t-1) (numérica)	7,1 %
var_transformada_t1	cambio del área transformada (numérica)	7,1 %
focos_t1	focos de calor (t-1) (numérica)	61,3 %
latitud	latitud (numérica)	0,1 %
longitud	longitud (numérica)	0,1 %
driver_dominante	causa dominante (categórica)	4,3 %

Desbalance de clases

«Alta» es el 25,2 % del entrenamiento y el 22,1 % de la prueba: aproximadamente una de cada cuatro filas. Un modelo que siempre prediga «No alta» acierta el 77,9 % de la prueba sin aprender nada. **Efecto:** la exactitud sola engaña; por eso se comparan el F1, la precisión y el recall de la clase Alta, el AUC y el MCC, y se muestra la matriz de confusión.

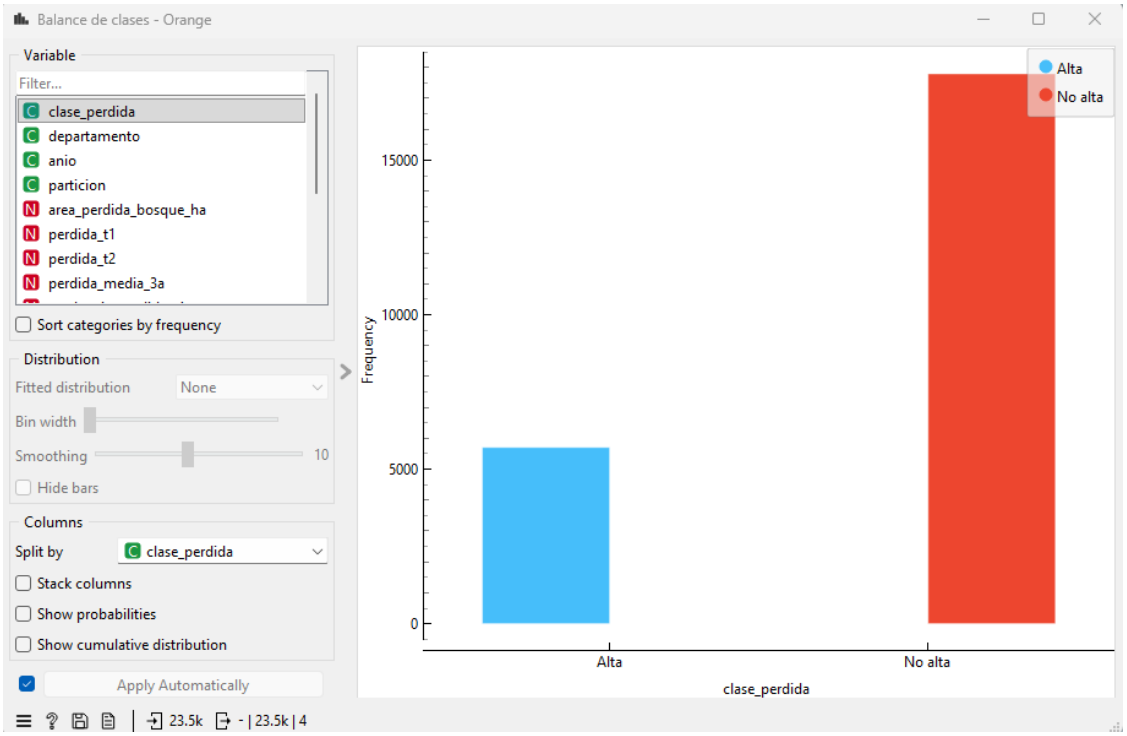


Figura 4. Distribución de la clase en Orange (Distributions).

Se ve que «No alta» predomina; por eso se evalúa la clase Alta.

4.2 Estrategia de evaluación

Los tres modelos reciben las mismas variables, la misma partición temporal y se evalúan en el mismo conjunto de prueba (widget Test and Score con *Test on test data* y clase objetivo Alta). No se usa validación cruzada aleatoria, porque mezclaría años.

Modelo	Widget	Parámetros
Regresión logística	Logistic Regression	regularización Ridge (L2), C = 1; variables estandarizadas e imputadas con el promedio

Modelo	Widget	Parámetros
Árbol de decisión	Tree	árbol binario; hojas con al menos 50 casos; no dividir subconjuntos de menos de 100; profundidad máxima 5; detener con mayoría del 95 %
Random Forest	Random Forest	200 árboles; no dividir subconjuntos de menos de 10; semilla fija; sin límite de profundidad

4.3 Resultados y comparación

Cifras de la verificación en Python (scikit-learn) con los mismos datos, partición y parámetros equivalentes. Las de Orange van en la captura de Test and Score y prevalecen si difieren.

Modelo	Exactitud	AUC	F1 (Alta)	Precisión	Recall	MCC
Predecir siempre «No alta»	0,779	0,500	0	—	0	0
Regla de persistencia (sin modelo)	0,936	—	0,858	0,842	0,874	0,817
Regresión logística	0,935	0,981	0,849	0,870	0,829	0,808
Árbol de decisión	0,930	0,978	0,845	0,824	0,867	0,800
Random Forest ★	0,933	0,982	0,852	0,832	0,873	0,809

Regla de persistencia: Alta si la pérdida del año anterior ya fue de 129 ha o más.



Figura 5. F1 de la clase Alta en la prueba 2019–2024.

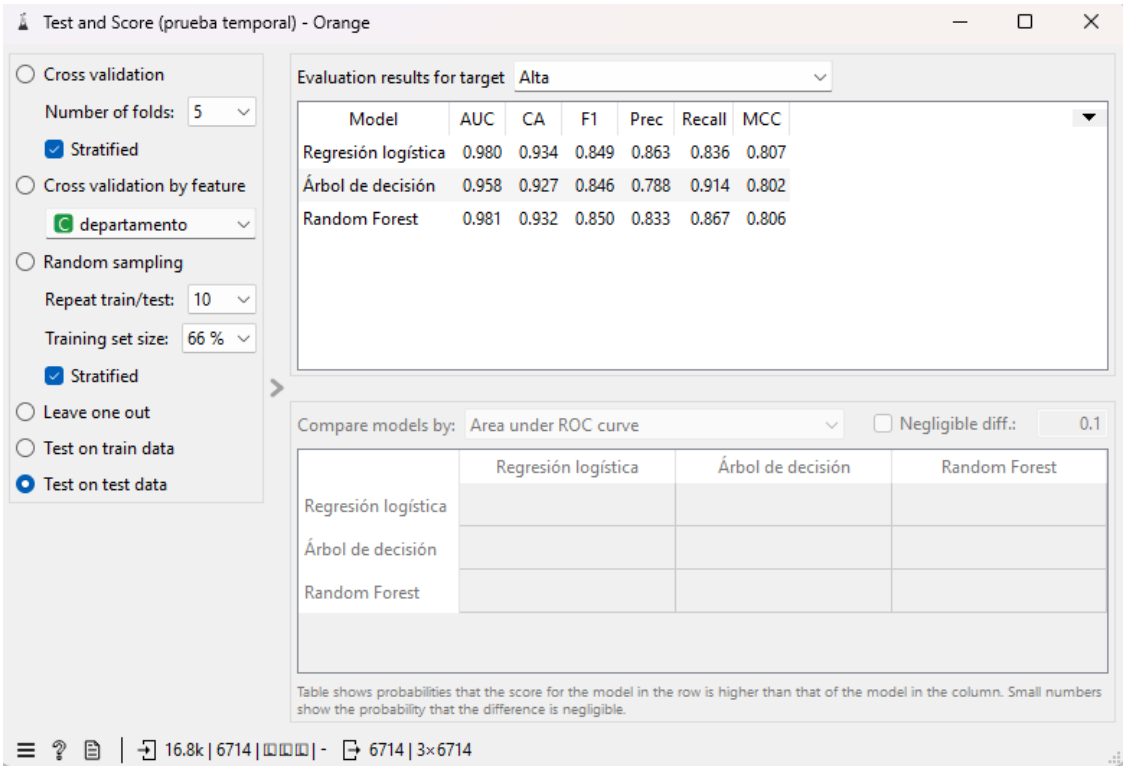


Figura 6. Test and Score de Orange con los tres modelos (prueba temporal).

Tabla de métricas de Orange (AUC, CA, F1, Precision, Recall, MCC) para la clase Alta.

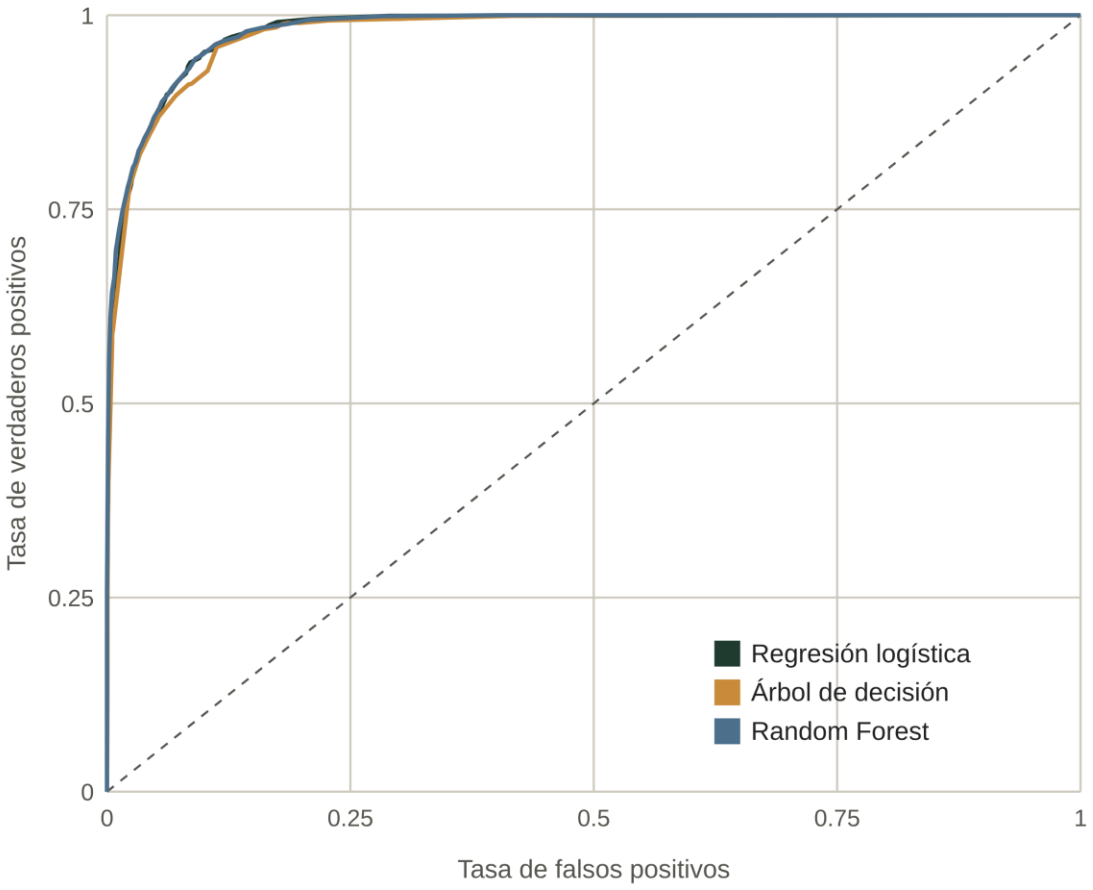


Figura 7. Curvas ROC de los tres modelos (verificación en Python).

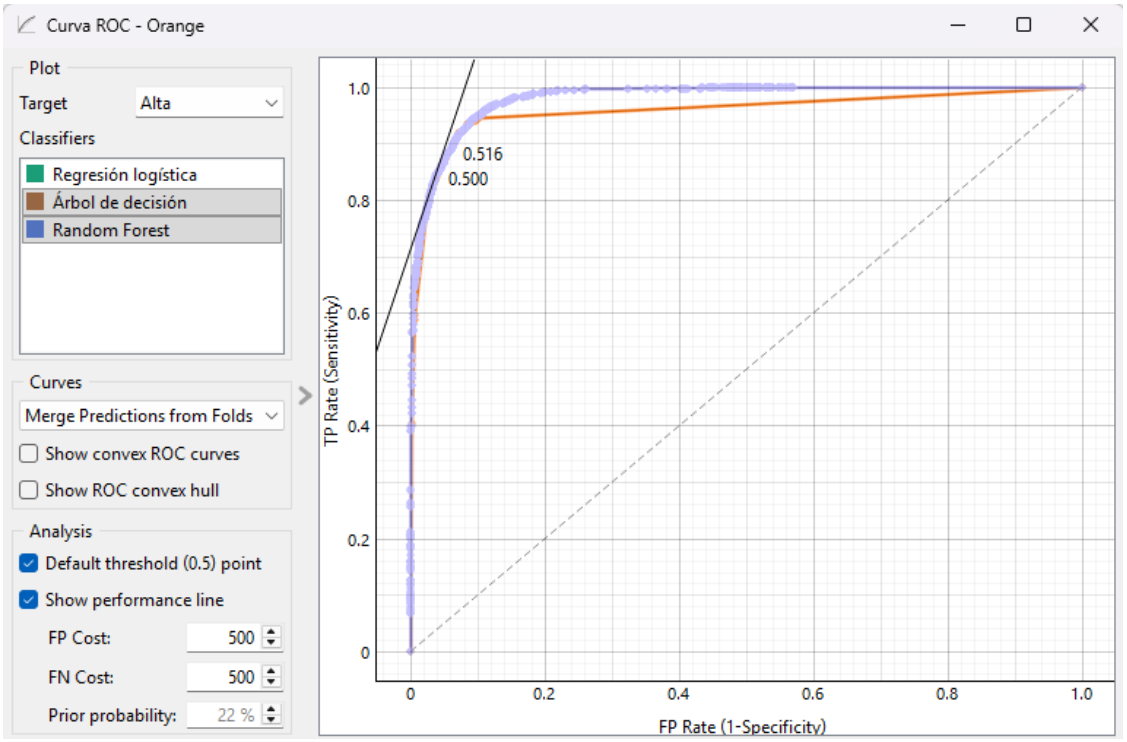


Figura 8. ROC Analysis de Orange.

Curvas ROC de los tres modelos para la clase Alta.

Matrices de confusión (prueba 2019–2024, clase Alta)

Modelo	No alta bien (VN)	Falsos positivos	Falsos negativos	Alta bien (VP)
Regresión logística	5.050	183	253	1.228
Árbol de decisión	4.959	274	197	1.284
Random Forest ★	4.971	262	188	1.293
Regla de persistencia	4.991	242	187	1.294

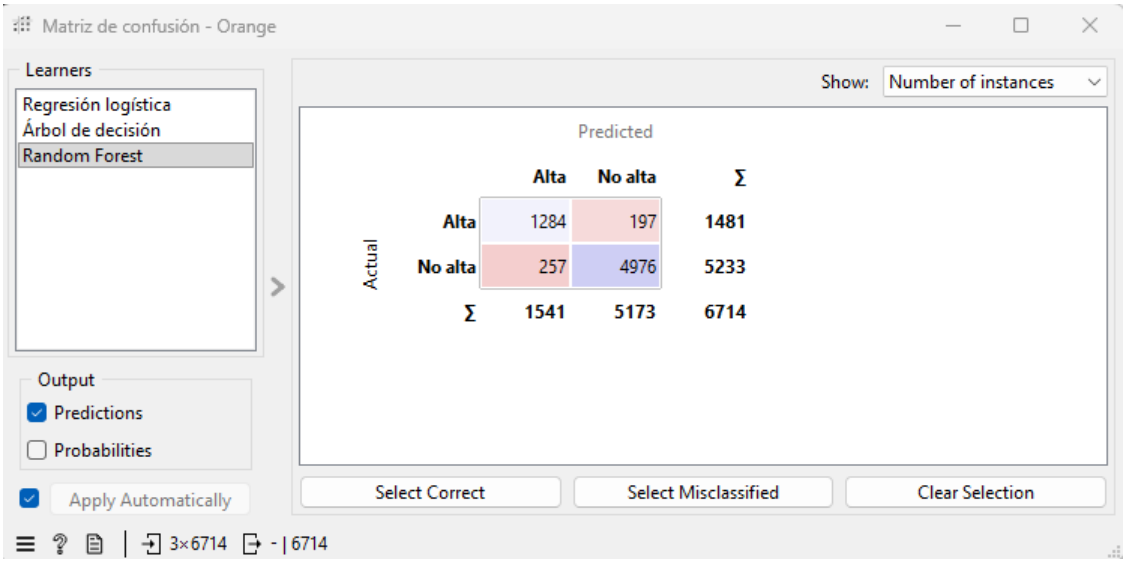


Figura 9. Matriz de confusión del modelo elegido en Orange.

Filas: clase real; columnas: clase predicha.

4.4 Selección del modelo

Se selecciona el Random Forest con el criterio «mayor F1 de la clase Alta (equilibra precisión y recall); a igualdad, mayor AUC».

- **Desempeño.** En Orange (Test and Score), F1 de 0,850, AUC de 0,981, recall de 0,867 y precisión de 0,833 en la clase Alta. Las diferencias con la regresión logística (F1 0,849) y el árbol (F1 0,846) son de milésimas: los tres modelos rinden prácticamente igual. El árbol tiene el mayor recall (0,914), a cambio de una precisión menor (0,788). En la verificación en Python el orden es el mismo (F1 0,852, 0,849 y 0,845).
- **Errores.** En Orange, 197 municipio-años de la prueba que sí fueron «Alta» no se detectaron (falsos negativos) y 257 se anunciaron sin serlo (Figura 9). En la verificación en Python, en el 71 % de los falsos negativos la pérdida del año anterior estaba por debajo del umbral: son municipios que cruzan el umbral sin haberlo superado antes.
- **Por año.** El recall baja en 2023 (0,80) frente a 2022 (0,89); no se identificó la causa.
- **Interpretabilidad.** El árbol de profundidad 5 usa casi solo el promedio de los tres años previos (corte principal en 100,8 ha); la regresión logística da el mayor peso a esa misma variable.

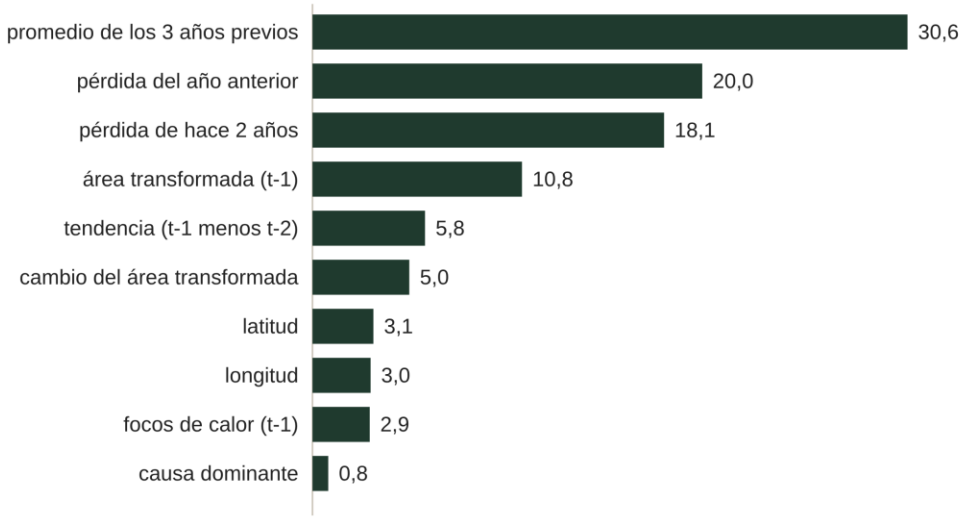


Figura 10. Importancia de las variables en el bosque aleatorio.

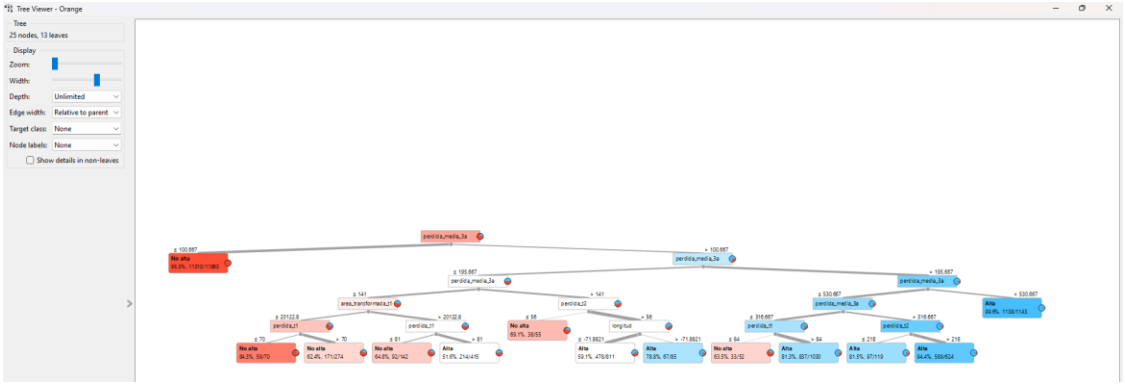


Figura 11. Tree Viewer de Orange.

Reglas del árbol de decisión.

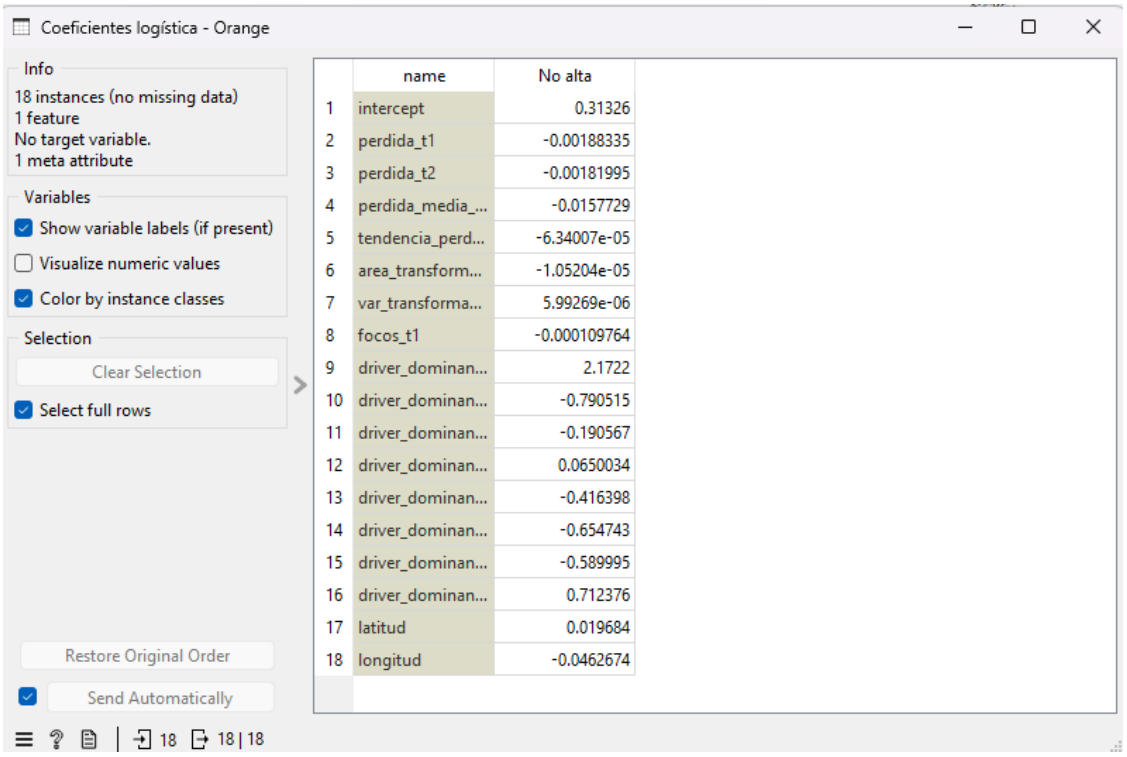


Figura 12. Coeficientes de la regresión logística en Orange.

Variables con mayor peso.

Qué aportan los modelos y cuáles son sus límites

- **Lo principal es la persistencia.** Las variables que más pesan son el promedio de los tres años previos, la pérdida del año anterior y la de hace dos años (en conjunto 69 % de la importancia). La regla sin modelo (Alta si el año anterior ya fue Alta) obtiene F1 0,858, igual o mejor que los tres modelos: **los modelos aprenden sobre todo que quien perdió mucho sigue perdiendo mucho**; no hay evidencia de que añadan información útil a esa regla.
- **La causa dominante no está anticipando nada.** Es la causa del mismo año y solo existe cuando hubo pérdida (las 1.008 filas sin causa nunca son Alta). Aun así, quitarla casi no cambia el resultado (F1 0,849 sin ella frente a 0,852 con ella) y reemplazarla por la del año anterior tampoco (0,853).
- **Latitud y longitud no identifican al municipio:** en el dataset son las del departamento en casi todos los registros. Sin ellas, F1 0,851 (prácticamente igual).

- **El umbral es una decisión propia.** Con otro percentil cambiaría el problema y las cifras.
- **Correlación, no causa:** los modelos describen asociaciones; no explican por qué pierde bosque un municipio.

5. Clustering: Implementación, Evaluación e Interpretación

5.1 Variables, tratamiento y algoritmo

Pregunta: ¿qué perfiles de municipios existen según su pérdida de bosque, su persistencia y evolución y el fuego y la transformación del suelo que los acompañan? **No se usa** la clase Alta/No alta ni la causa dominante.

Variable	Mide	Faltantes
log_perdida_media_anual	log(1 + pérdida media anual, ha)	0
proporcion_perdida_reciente	fracción de la pérdida ocurrida desde 2015	3
pendiente_perdida_rel	pendiente de la pérdida (relativa a su media)	0
variabilidad_perdida_cv	variabilidad anual de la pérdida (CV)	0
log_focos_medios	log(1 + focos de calor medios 2012–2022)	0
log_area_transformada_media	log(1 + área transformada media, ha)	80
crecimiento_transformada_pct	crecimiento del área transformada (%)	80

Tratamiento. Se imputan los 163 valores faltantes con el promedio (casi todos de área transformada) y se estandarizan las variables a media 0 y desviación 1, porque k-means usa distancia euclidiana y sin ello dominarían las de mayor magnitud. Los logaritmos evitan que unos pocos municipios amazónicos dominen la distancia. La pendiente y la proporción de pérdida reciente están muy correlacionadas (0,92): miden una evolución parecida y pesan doble en la distancia.

Algoritmo. k-means (widget k-Means de Orange): k-means++, 10 repeticiones, 300 iteraciones, k de 2 a 8, sobre 1.119 municipios.

5.2 Elección del número de grupos

k	Silueta	Davies-Bouldin	Calinski-Harabasz	Tamaños
2	0,297	1,33	498	616 · 503
3	0,256	1,40	410	500 · 365 · 254
4 ★	0,264	1,29	365	475 · 320 · 285 · 39
5	0,223	1,35	344	333 · 277 · 266 · 205 · 38

k	Silueta	Davies-Bouldin	Calinski-Harabasz	Tamaños
6	0,230	1,26	332	305 · 287 · 231 · 207 · 51 · 38
7	0,225	1,24	317	294 · 256 · 205 · 182 · 120 · 38 · 24
8	0,203	1,28	301	221 · 211 · 177 · 173 · 171 · 114 · 27 · 25

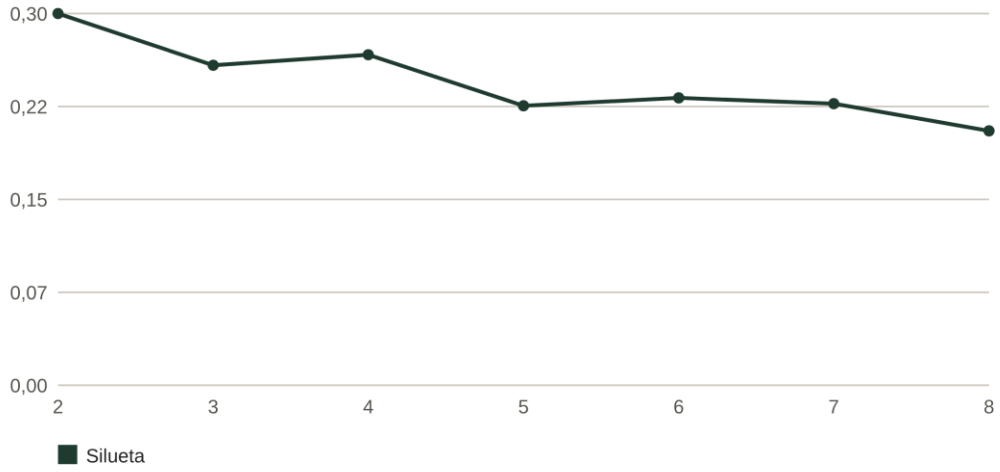


Figura 13. Silueta promedio según el número de grupos.

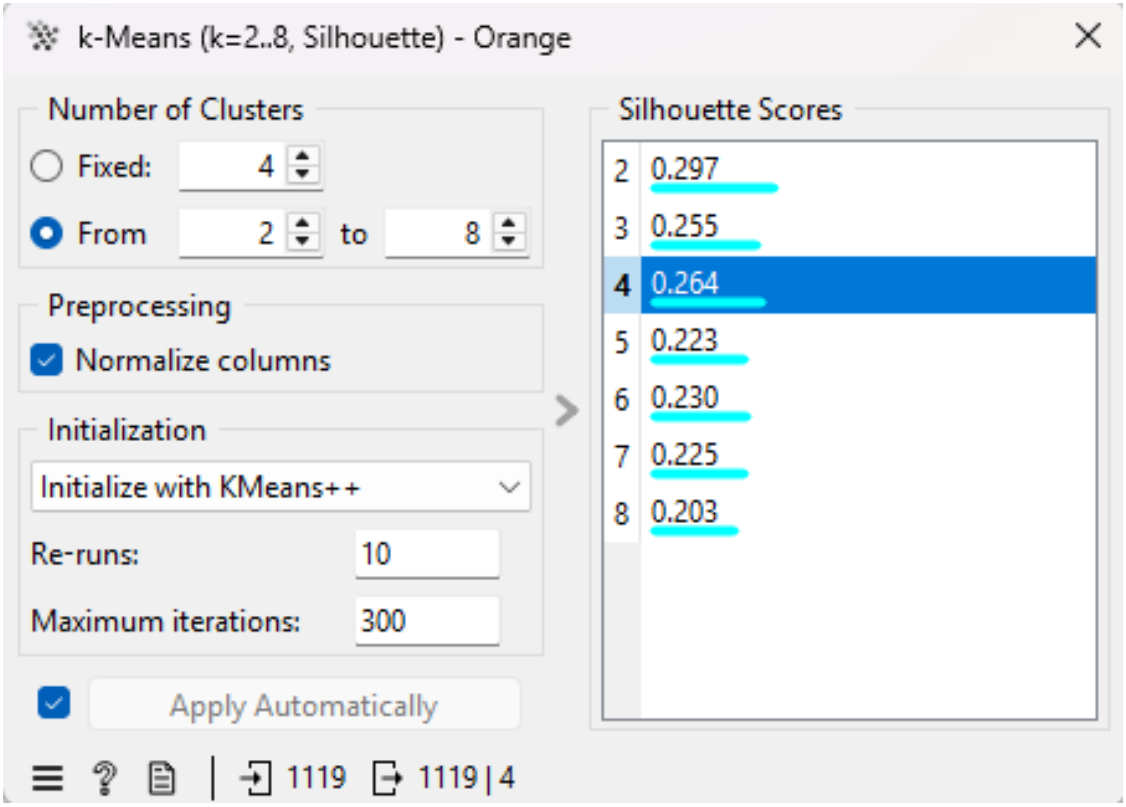


Figura 14. Silueta por número de grupos en Orange (k-Means, de 2 a 8).

Orange calcula la silueta de cada k; la más alta es la de k = 2 (0,297) y se selecciona k = 4 (0,264). En Orange los grupos se numeran distinto: C4 = grupo 1, C1 = grupo 2, C3 = grupo 3 y C2 = grupo 4.

La silueta más alta es la de **k = 2 (0,297)**, que solo separa pérdida «mucha» de «poca». Se elige **k = 4 (silueta 0,264)** por ser la mayor entre los k ≥ 3 con grupos no menores al 2 % de los municipios, con un Davies-Bouldin entre los más bajos (1,29) y porque aísla un grupo pequeño de frentes de pérdida que k = 2 y k = 3 no distinguen. Es una decisión de utilidad, no solo de la medida. Una silueta de 0,26 indica una estructura **débil a moderada**: los grupos sirven para describir y priorizar, pero sus fronteras son difusas.

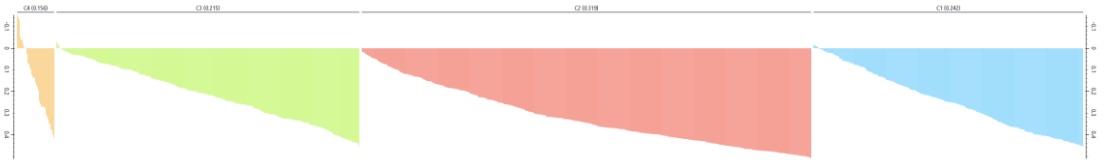


Figura 15. Silhouette Plot de Orange para k = 4 (imagen girada para que quepa en la página).

Muestra la cohesión de cada grupo; el grupo 1 (C4) tiene la silueta más baja (0,156) y algunos municipios con silueta negativa; C1 = 0,242, C2 = 0,319, C3 = 0,215.

5.3 Caracterización de los grupos

Grupo	Municipios	Pérdida media anual (ha, mediana)	% de la pérdida total	Pérdida reciente (%)	Silueta
1 · Frentes de mayor pérdida	39 (3,5 %)	709	38 %	56 %	0,16
2 · Pérdida alta sostenida	285 (25,5 %)	217	46 %	40 %	0,24
3 · Pérdida moderada	320 (28,6 %)	42	12 %	48 %	0,21
4 · Pérdida baja y en descenso	475 (42,4 %)	13	4 %	15 %	0,32

Grupo 1 · Frentes de mayor pérdida

39 municipios con pérdida media anual mediana de 709 ha, el 38 % de la pérdida total de los municipios, 56 % de ella en el último tramo del periodo y un índice de focos de calor

(logaritmo) de 5,4. **Ejemplos:** San Vicente del Caguán (Caquetá), La Macarena (Meta), Cartagena del Chairá (Caquetá), San José del Guaviare (Guaviare). **Departamentos más frecuentes:** Bolívar (8), Casanare (5), Meta (5), Antioquia (4).

Grupo 2 · Pérdida alta sostenida

285 municipios con pérdida media anual mediana de 217 ha, el 46 % de la pérdida total de los municipios, 40 % de ella en el último tramo del periodo y un índice de focos de calor (logaritmo) de 4,4. **Ejemplos:** Cumaribo (Vichada), Puerto Leguízamo (Putumayo), Arauquita (Arauca), Puerto Asís (Putumayo). **Departamentos más frecuentes:** Antioquia (35), Cesar (23), Magdalena (22), Tolima (17).

Grupo 3 · Pérdida moderada

320 municipios con pérdida media anual mediana de 42 ha, el 12 % de la pérdida total de los municipios, 48 % de ella en el último tramo del periodo y un índice de focos de calor (logaritmo) de 1,9. **Ejemplos:** La Uribe (Meta), Vista Hermosa (Meta), Puerto Inírida (Guainía), El Carmen del Darién (Chocó). **Departamentos más frecuentes:** Antioquia (52), Boyacá (27), Santander (26), Caldas (23).

Grupo 4 · Pérdida baja y en descenso

475 municipios con pérdida media anual mediana de 13 ha, el 4 % de la pérdida total de los municipios, 15 % de ella en el último tramo del periodo y un índice de focos de calor (logaritmo) de 1,6. **Ejemplos:** Barbacoas (Nariño), Retiro (Antioquia), Puerto Triunfo (Antioquia), Calima (Valle del Cauca). **Departamentos más frecuentes:** Cundinamarca (100), Boyacá (93), Santander (46), Nariño (43).

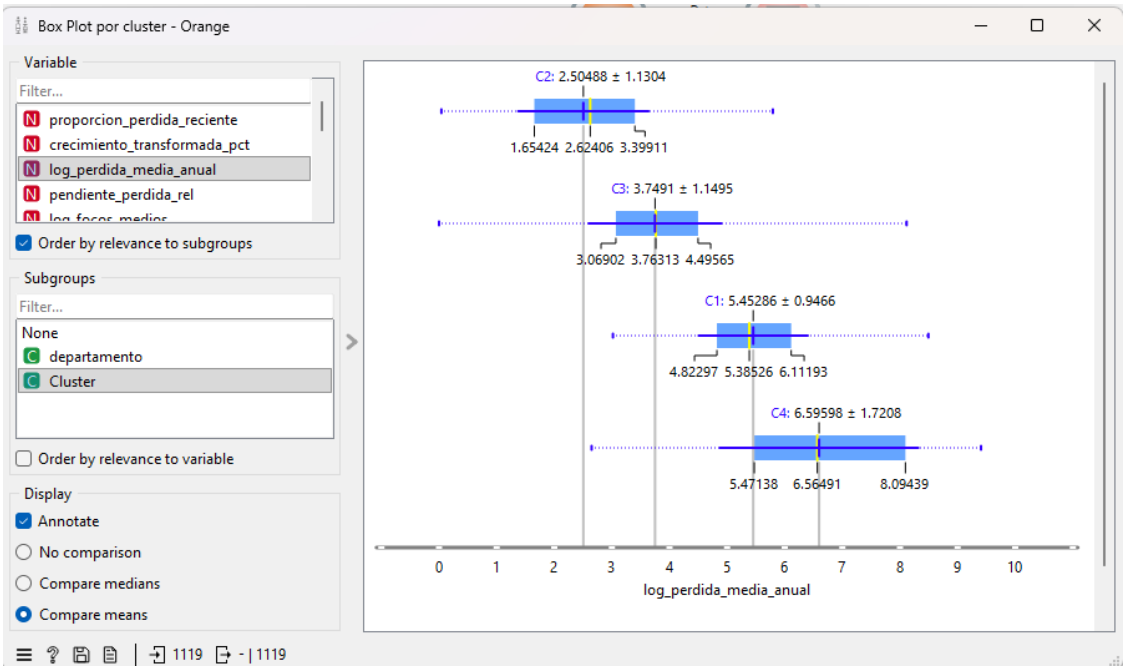


Figura 16. Box Plot de Orange por grupo: log_perdida_media_anual (C4 = grupo 1, C1 = grupo 2, C3 = grupo 3, C2 = grupo 4).

Qué variables distinguen a cada grupo. La variable está en escala log(1 + ha): C4 tiene la media más alta (6,60) y C2 la más baja (2,50).

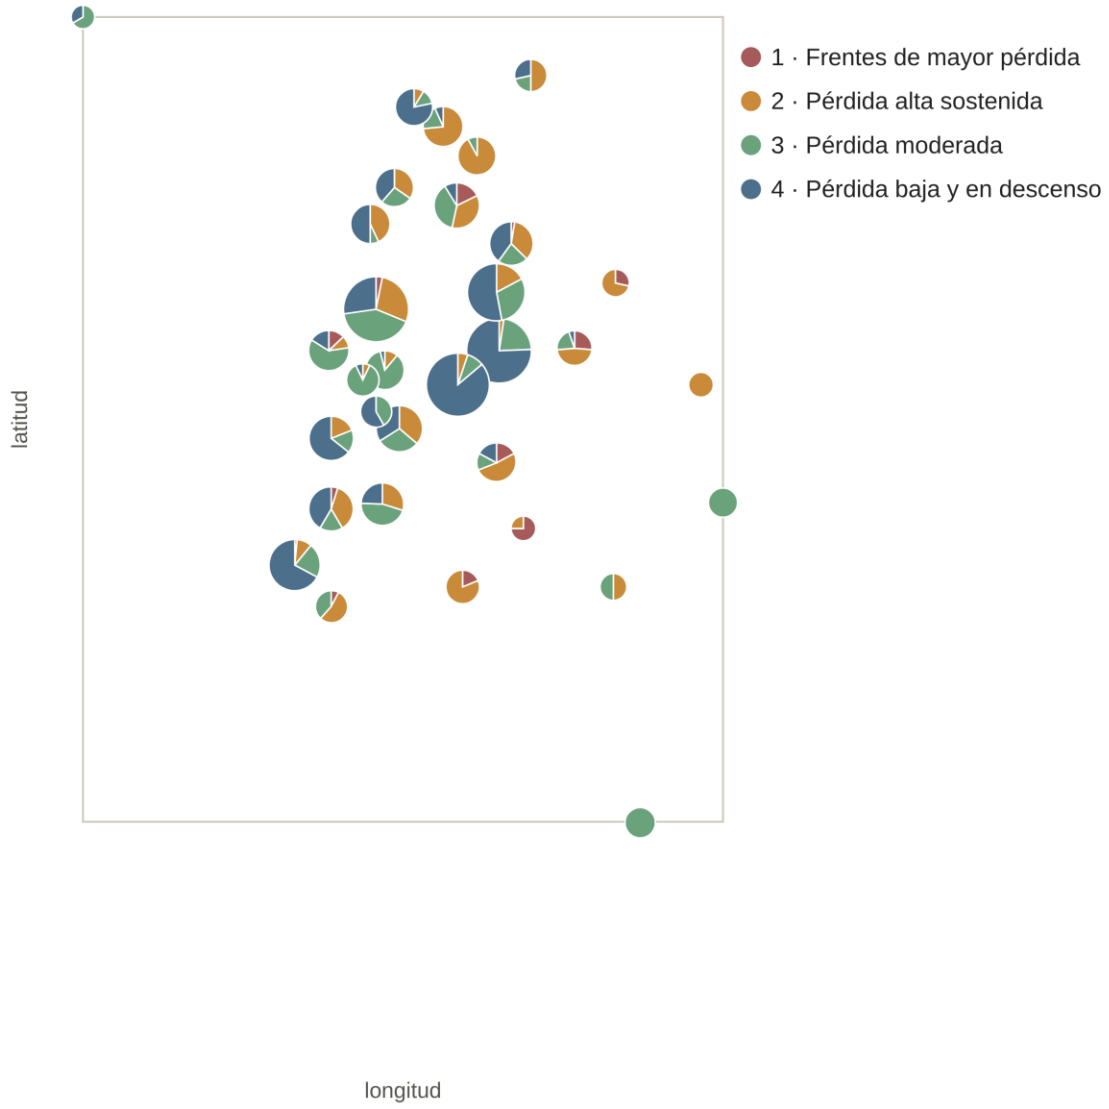


Figura 17. Municipios de cada grupo según el departamento (las coordenadas del dataset son las del departamento).

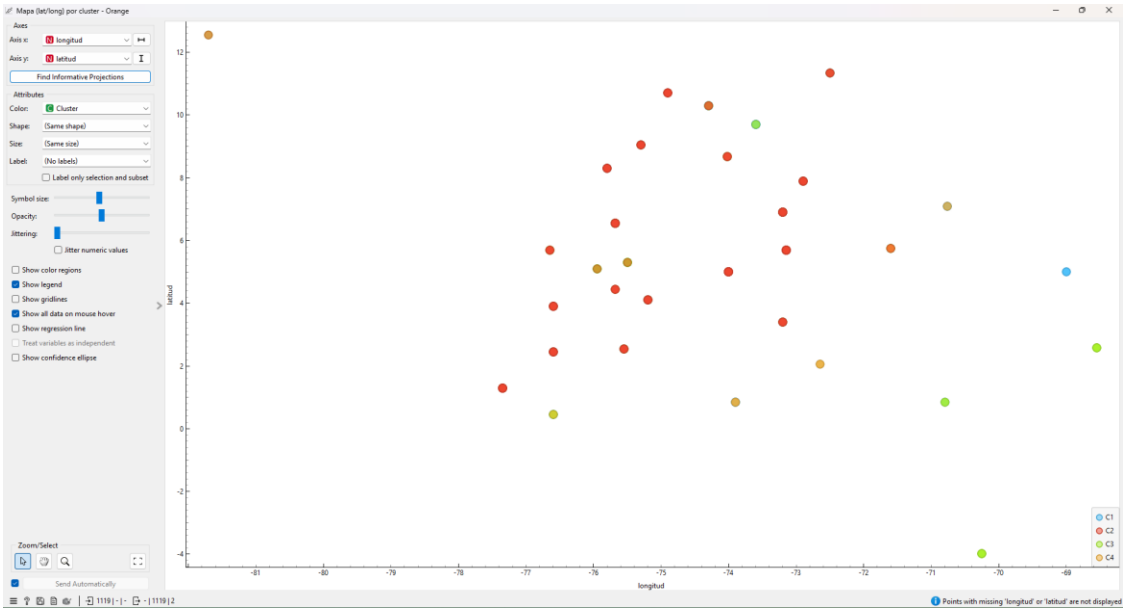
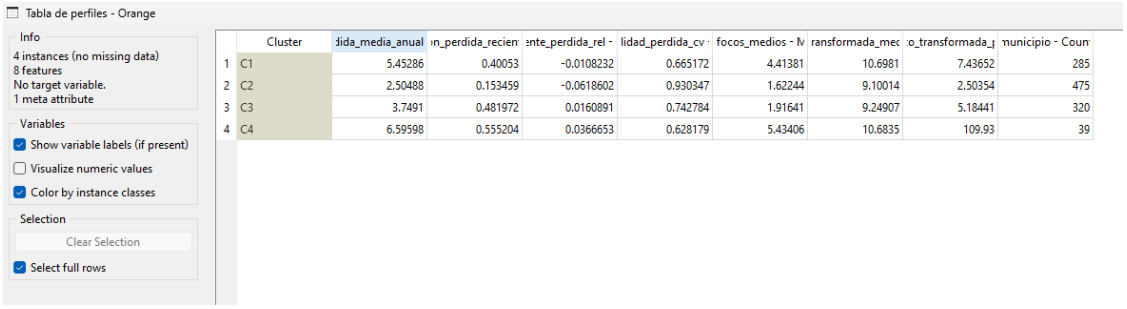


Figura 18. Scatter Plot de Orange (longitud y latitud) por grupo (C4 = grupo 1, C1 = grupo 2, C3 = grupo 3, C2 = grupo 4).

Los puntos se apilan por departamento; no es un mapa municipal.



	Cluster	dida_media_anual	ın_perdida_recien	ente_perdida_rel -	lidad_perdida_cv	focos_medios - M	ransformada_mec	o_transformada_	nunicipio - Coun
1	C1	5.45286	0.40053	-0.0108232	0.665172	4.41381	10.6981	7.43652	285
2	C2	2.50488	0.153459	-0.0618602	0.930347	1.62244	9.10014	2.50354	475
3	C3	3.7491	0.481972	0.0160891	0.742784	1.91641	9.24907	5.18441	320
4	C4	6.59598	0.555204	0.0366653	0.628179	5.43406	10.6835	109.93	39

Figura 19. Group By de Orange: perfil promedio por grupo (C4 = grupo 1, C1 = grupo 2, C3 = grupo 3, C2 = grupo 4).

Medias de las 7 variables y cantidad de municipios: C1 285, C2 475, C3 320 y C4 39, los mismos tamaños de la verificación en Python.

Relación con el modelo supervisado y apoyo a decisiones

Como contraste (la clase no entró al clustering), se cuenta qué parte de los municipio-años «Alta» de la prueba cae en cada grupo.

Grupo	Municipio-años en la prueba	Alta	% Alta	Recall del modelo
1 · Frentes de mayor pérdida	234	198	84,6 %	0,96
2 · Pérdida alta sostenida	1.710	961	56,2 %	0,91
3 · Pérdida moderada	1.920	315	16,4 %	0,72
4 · Pérdida baja y en descenso	2.850	7	0,2 %	0,14

- Los grupos 1 y 2 reúnen el 78 % de los municipio-años Alta; en el grupo 1, el 85 % de sus municipio-años es Alta.
- El grupo 1 (3,5 % de los municipios) concentra el 38 % de la pérdida media anual: es donde priorizar monitoreo. No es un grupo solo amazónico: incluye municipios de Bolívar, Casanare, Meta y Antioquia.
- El grupo 4 (zona andina, mayoría de Cundinamarca y Boyacá) tiene pérdida baja y en descenso; casi nunca es Alta. El modelo lo reconoce poco, pero hay apenas 7 casos.
- **Limitaciones:** estructura débil a moderada; las variables dependen de lo que detecta Global Forest Watch (pérdida de cobertura arbórea), no de la deforestación legal o ilegal; la ubicación solo llega al departamento.

6. Comentarios de YouTube: Conexión, Extracción, Preparación y Análisis

6.1 Propósito y procedimiento de conexión a la API

Propósito: conocer qué causas, responsables y propuestas mencionan quienes comentan videos sobre deforestación en Colombia y contrastarlo con los datos. Los comentarios son los de quienes comentaron los videos elegidos y **no representan a la población**.

- En Google Cloud Console se crea un proyecto, se habilita **YouTube Data API v3** y se crea una clave de API.
- La clave **no se publica**: el script conocimiento_oculto/extraer_comentarios_youtube.py la lee de la variable de entorno YOUTUBE_API_KEY.
- El script busca videos (search.list), consulta sus datos (videos.list) y lee los comentarios principales (commentThreads.list) con paginación. No guarda nombres, canales ni identificadores de los autores: el identificador del comentario es un código (hash). Solo usa la biblioteca estándar de Python.
- La cuota diaria es de 10.000 unidades; esta extracción usó 504.

6.2 Criterios de búsqueda y selección, videos consultados y restricciones

Criterio	Valor
Fecha de extracción (UTC)	2026-11-12
Consultas de búsqueda	deforestación Colombia Amazonía; deforestación Caquetá Guaviare ganadería; deforestación Colombia coca minería; acaparamiento de tierras Amazonía colombiana; incendios forestales Colombia deforestación
Filtros	videos publicados desde 2018-01-01; idioma de relevancia es; región CO; orden por relevancia; al menos 30 comentarios por video; máximo 500 comentarios por video; solo comentarios principales (sin respuestas)
Videos encontrados / usados	25 / 3

Código	Video	Canal	Fecha del video	Enlace	Comentarios en el video	Obtenidos	Útiles
V1	Así se ve la tragedia ambiental originada por la deforestación en el Amazonas	Noticias Caracol	2023-12-26	eXCOqULKEBo	49	29	28
V2	La deforestación es “el problema ambiental más grave de Colombia”, según expertos	Noticias Caracol	2021-02-15	dzoEvoKNZQA	105	61	49
V3	¿Qué es la DEFORESTACIÓN? Causas, consecuencias y posibles soluciones	Astraway	2021-11-07	z4XzCA75JLs	102	80	40

Restricciones encontradas:

- Solo se leyeron 117 comentarios principales de 3 videos (los más relevantes según YouTube, no una muestra aleatoria).
- Quien comenta no representa a la población: hay estudiantes que usan el video para una tarea y personas de otros países.
- Las respuestas a los comentarios no se extrajeron; el orden «relevancia» favorece los comentarios con más interacción.
- El idioma se detectó con una heurística de palabras funcionales; quedan comentarios fuera de tema que el filtro automático no detecta.
- Solo 3 de los 25 videos encontrados cumplieron los filtros; el corpus es pequeño.
- No se extrajeron respuestas a los comentarios.
- No se guardan datos personales de los autores.

6.3 Preparación de los comentarios

Se limpiaron los comentarios dejando constancia de cada decisión. Se descartaron los muy cortos, los formados solo por emojis o símbolos y los duplicados; no hubo vacíos, spam ni comentarios en otro idioma. La normalización lingüística (minúsculas, acentos, palabras vacías y lematización) se hace en Orange con Preprocess Text.

Decisión de limpieza	Comentarios
Comentarios extraídos	170
Vacíos	0
Muy cortos	31
Solo emojis o símbolos	21
Duplicados	1
Otro idioma	0
Spam o enlaces	0
Comentarios útiles	117

6.4 Análisis y resultados

Se analizaron 117 comentarios de 3 videos (mediana de 13 palabras; publicados entre 2021 y 2026).

Uso del video. El 22 % de los comentarios (26) es de estudiantes que usan el video para una tarea o exposición, sobre todo en el video de divulgación (V3: 45 %). Solo el 29 % (34) menciona una causa o un responsable; el resto es agradecimiento, emoción o comentarios generales. Por eso el corpus dice poco sobre las causas y bastante sobre cómo se recibe un video.

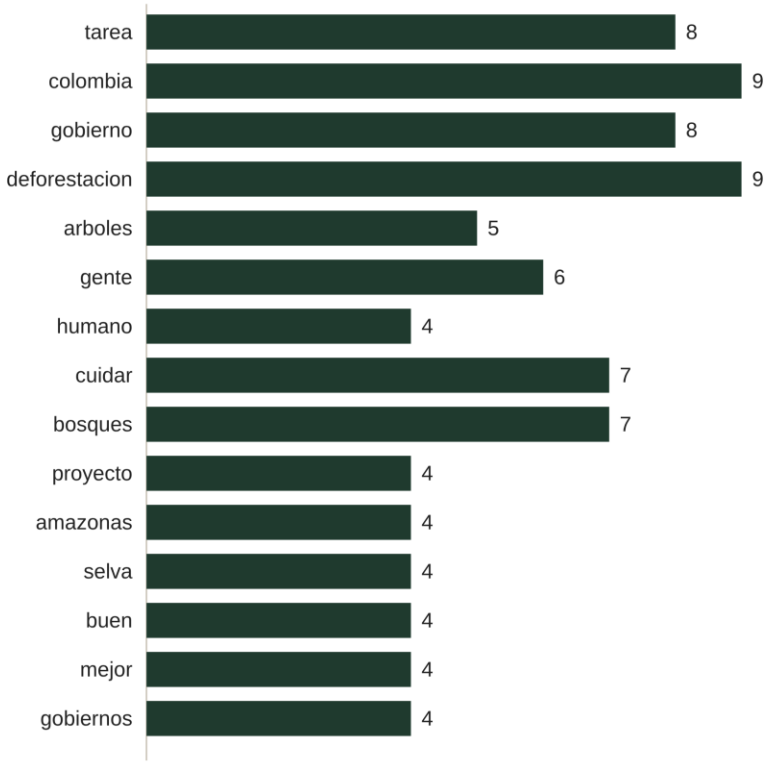


Figura 20. Comentarios que mencionan cada término (TF-IDF, sin palabras vacías).

Temas (5)

Tema	Términos principales	Comentarios	Ejemplos
1	tarea, bueno, ayuda, muchas, proyecto, estoy, amazonas	44 (38 %)	*«Gracias por tu vídeo me sirve para mi tarea.»* *«Gracias lo ocupo para mi tarea ❤»*
2	colombia, deforestacion, gobiernos, pais, bueno, arboles, coca	23 (20 %)	*«Los anteriores gobiernos de Brasil, Colombia y Perú no hicieron casi nada para frenar la deforestacion de la Amazonia.»* *«Donde esta el presidente de Colombia que no se ve por ningún lado, supuestamente el logo de su campaña era atacar la deforestación, minería que está matando el país»*
3	gobierno, mejor, sino, politicos, tenemos, recursos, pais	11 (9 %)	*«Q HACE EL GOBIERNO Q NO PONE LEY A ESE PERJUICIO»* *«A este gobierno todo se le va en bla bla bla y no toma accion en nada»*
4	ambiente, cuidar, medio, noticia, recursos, gente, buen	13 (11 %)	*«Hay qu cuidar el medio ambiente»* *«Hay que cuidar el medio ambiente»*

Tema	Términos principales	Comentarios	Ejemplos
5	humano, gente, bosques, vida, arboles, importa, selva	26 (22 %)	*«Siento dolor al ver estas imágenes. No puedo creer que haya gente tan estúpida que se dedique a dañar tan inigualable belleza. Sin bosques, no hay agua; y sin agua, no hay vida para el humano y el…»* *«La gente quiere seguir teniendo lluvia aún tras cargarse los bosques □»*

Temas obtenidos en la verificación en Python (NMF); el LDA de Orange puede ordenarlos y nombrarlos distinto. Interpretación: tema 1, uso escolar y agradecimientos; temas 2 y 3, reclamo al gobierno; tema 4, cuidar el ambiente; tema 5, el ser humano y el bosque.

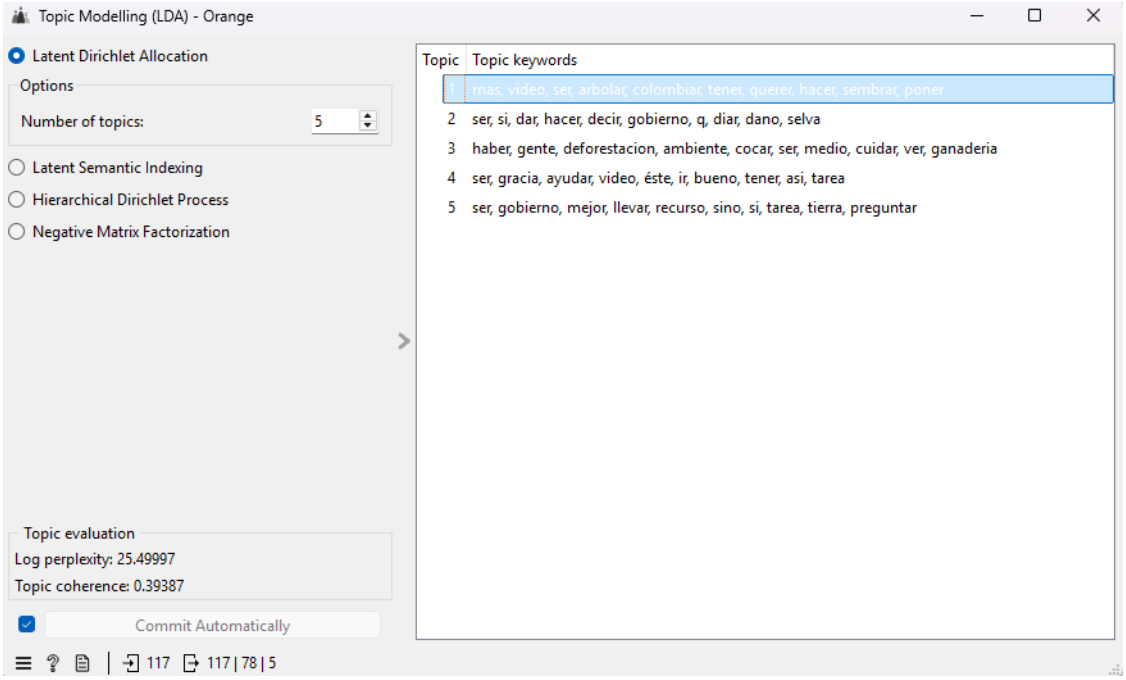


Figura 21. Topic Modelling (LDA) de Orange, 5 temas.

Términos principales de cada tema. En Orange los temas LDA quedan dominados por verbos y palabras frecuentes (ser, tener, hacer, si) y por formas erróneas del lematizador (colombiar, arbolar, cocar), por lo que la interpretación de los temas se apoya en la verificación con NMF. Coherencia de los temas: 0,394.

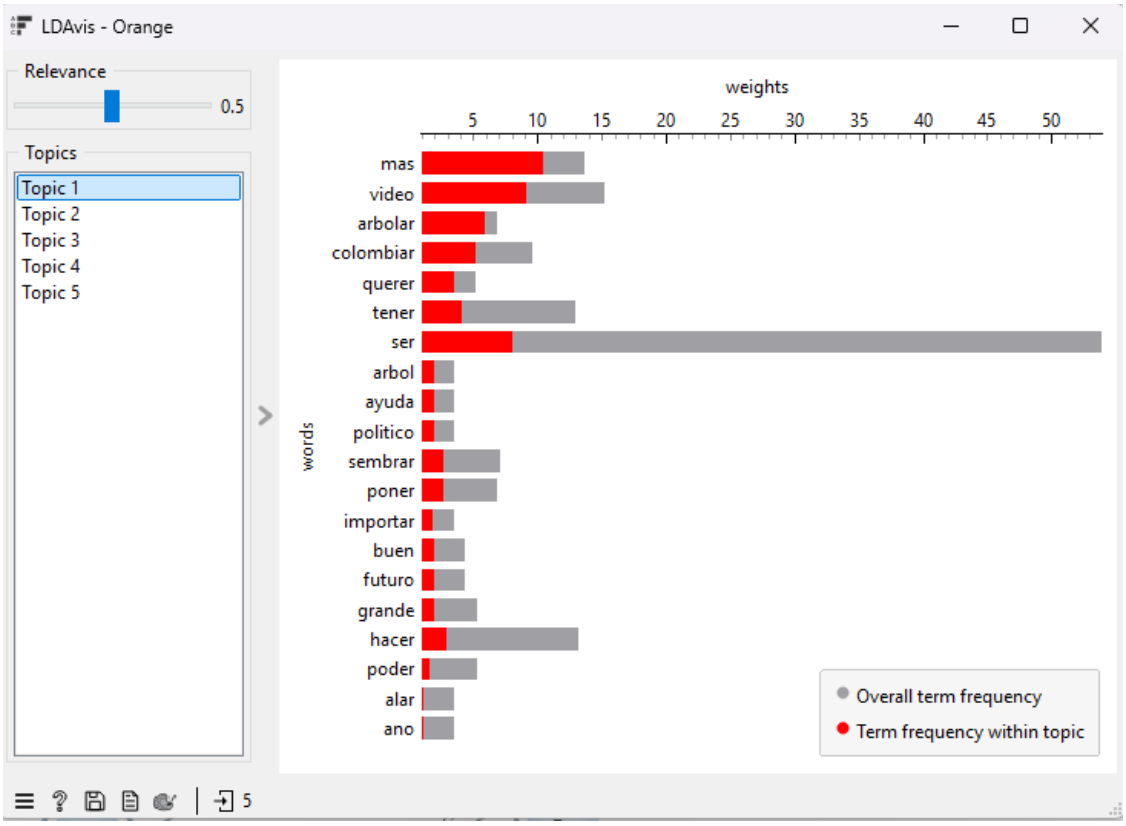


Figura 22. LDAvis de Orange.

Distancia entre temas y términos más relevantes.

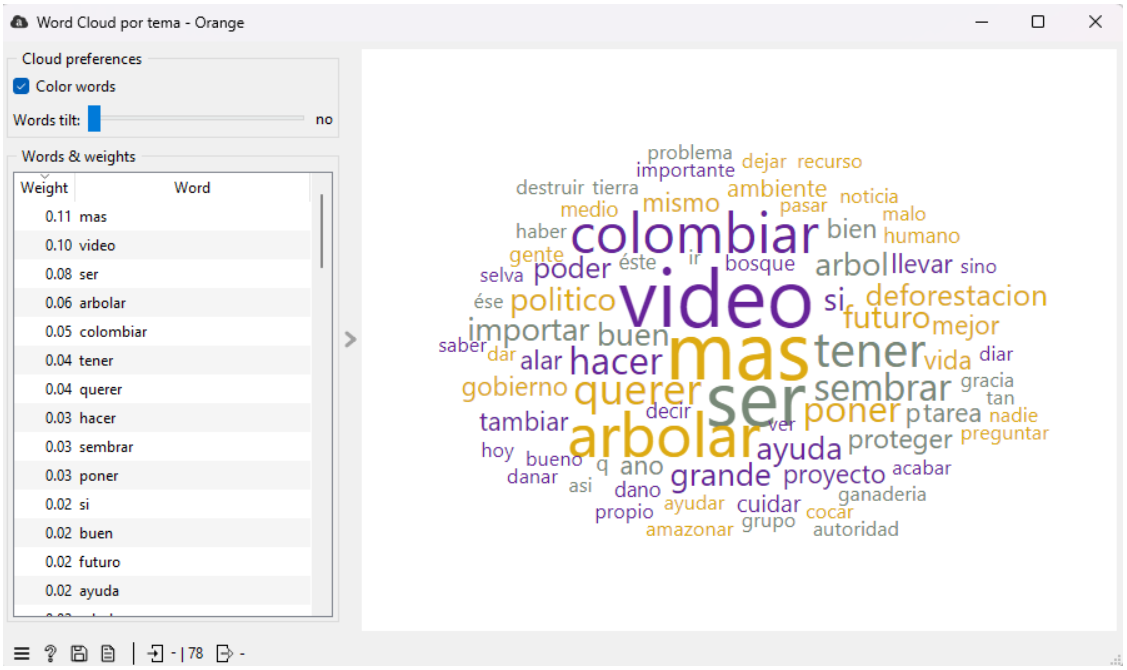


Figura 23. Word Cloud de un tema en Orange.

Apoyo visual; el análisis se sustenta en los temas y los ejemplos.

Qué causas, responsables y propuestas mencionan

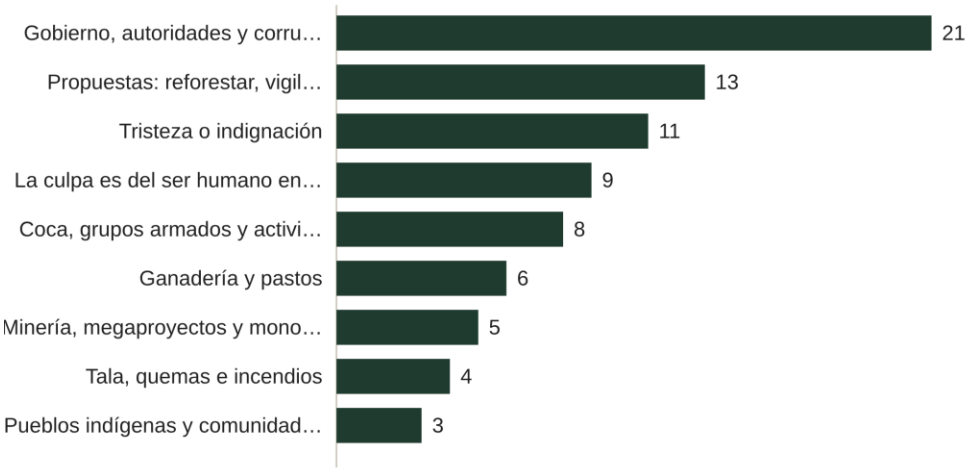


Figura 24. Comentarios que mencionan cada tipo de tema (un comentario puede tener varios; reglas de palabras clave).

Tipo de tema	Comentarios	Ejemplo
Gobierno, autoridades y corrupción	21 (18 %)	*«Los anteriores gobiernos de Brasil, Colombia y Perú no hicieron casi nada para frenar la deforestacion de la Amazonia.»*
Propuestas: reforestar, vigilar o sancionar	13 (11 %)	*«Estamos condenados a cadenas y cadenas de pandemias , los árboles son importantes no solo por el oxígeno , ayudan a la biosfera a equilibrar las emisiones de gases que ca…»*
Tristeza o indignación	11 (9 %)	*«que naturaleza le vamos a dejar a futuras generaciones que lastima el ser humano pensando primero en el dinero y no en la naturaleza»*
La culpa es del ser humano en general	9 (8 %)	*«que naturaleza le vamos a dejar a futuras generaciones que lastima el ser humano pensando primero en el dinero y no en la naturaleza»*
Coca, grupos armados y actividades ilegales	8 (7 %)	*«Pero no es por causa de las actividades ilegales, si bien causan sus daños ambientales, son los mega proyectos de extracción de minerales y los monocultivos (de Palma en …»*
Ganadería y pastos	6 (5 %)	*«Soy del CAQUETA y es muy sierto la de forestación es muy evidente más que todo lo acen para senbrar pastos para el ganado»*
Minería, megaproyectos y monocultivos	5 (4 %)	*«Pero no es por causa de las actividades ilegales, si bien causan sus daños ambientales, son los mega proyectos de extracción de minerales y los monocultivos (de Palma en …»*
Tala, quemas e incendios	4 (3 %)	*«Cada tienen proyectos campestres de vivienda, o rural, se ve siempre la quema, el gobierno no debería acceder a licencias de construcción de x vida en los sitios afectado…»*
Pueblos indígenas y comunidades rurales	3 (3 %)	*«Pero no es por causa de las actividades ilegales, si bien causan sus daños ambientales, son los mega proyectos de extracción de minerales y los monocultivos (de Palma en …»*

Estas familias se contaron con reglas de palabras clave en Python; son una verificación de lo que se ve en Orange con el Corpus Viewer y no un análisis de sentimiento.

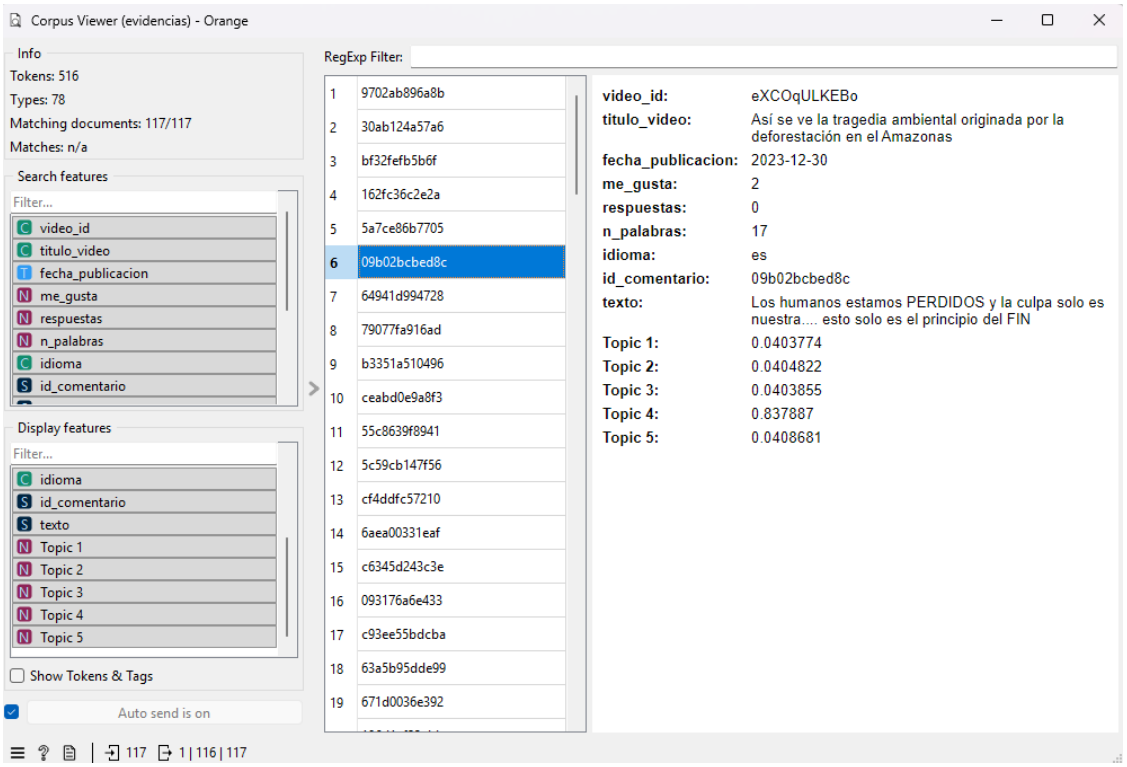


Figura 25. Corpus Viewer de Orange con ejemplos.

Comentarios que sustentan cada hallazgo.

Agrupación de comentarios

Se agruparon los comentarios con distancia coseno y enlace Ward. La silueta es muy baja (0,09 con 4 grupos), por lo que la agrupación solo confirma que hay un grupo grande de comentarios generales y unos pocos grupos pequeños; no se interpreta como segmentos de opinión.

Grupo	Comentarios	Términos	Ejemplo
1	87 (74 %)	gente, humano, arboles, proyecto, amazonas, selva	*«Siento dolor al ver estas imágenes. No puedo creer que haya gente tan estúpida que se dedique a dañar tan inigualable belleza. Sin bosques, no hay agua; y sin agua, no hay vida para el humano y el…»*
2	16 (14 %)	colombia, deforestacion, buen, buena, mejor, cuidar	*«Los anteriores gobiernos de Brasil, Colombia y Perú no hicieron casi nada para frenar la deforestacion de la Amazonia.»*

Grupo	Comentarios	Términos	Ejemplo
3	8 (7 %)	gobierno, sino, mejor, politicos, tenemos, arbol	*«Las. Entidades. Del. Gobierno. Son. Sino. Fachadas. De. Corucion. Uno. Reporta. No. Asen. Caso. Ni ponen. Atención.»*
4	6 (5 %)	tarea, muchas, ambiente, acabar, arbol, arboles	*«vine de una tarea de un codigo QR :v»*

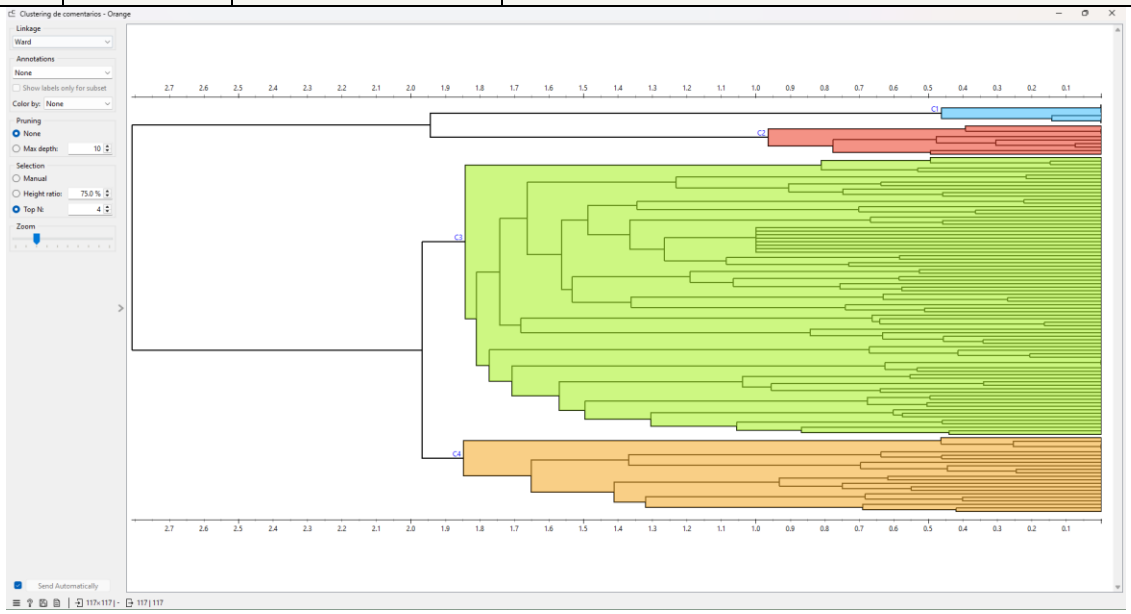


Figura 26. Hierarchical Clustering de Orange.

Dendrograma de los comentarios (Ward, 4 grupos). En Orange: C1 6, C2 9, C3 80 y C4 22 comentarios; como en Python, un grupo grande y varios pequeños.

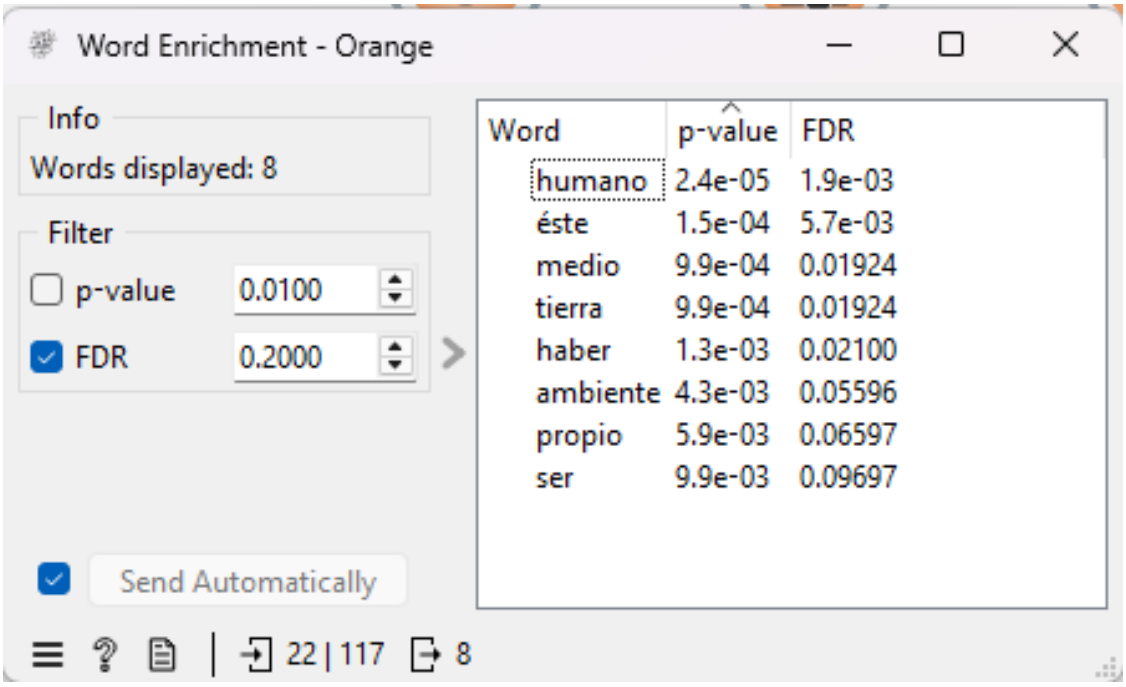


Figura 27. Word Enrichment de Orange.

Términos que caracterizan al grupo seleccionado frente al resto. Grupo C4 (22 comentarios): humano, medio, tierra y ambiente (FDR ≤ 0,2).

Territorios mencionados y sesgos

Los comentarios que nombran un lugar se refieren a la Amazonía, Caquetá o Guaviare (7), a otras regiones de Colombia (10) o a otros países o escriben desde ellos (5).

No representatividad. Solo se leyeron 117 comentarios principales de 3 videos (los más relevantes según YouTube, no una muestra aleatoria). Quien comenta no representa a la población: hay estudiantes que usan el video para una tarea y personas de otros países. Las conclusiones sobre los comentarios valen para este corpus, no para la población.

7. Conclusiones Integradas

Hallazgos respaldados por evidencia

- La pérdida alta de un municipio se anticipa con alta exactitud (F1 0,850, AUC 0,981 en Orange en 2019–2024), pero casi toda la capacidad viene de la persistencia: la regla «Alta si el año anterior ya fue Alta» logra F1 0,858.
- Quitar la causa dominante, las coordenadas o cambiar de modelo casi no altera el resultado (F1 entre 0,849 y 0,853).
- Hay 4 perfiles de municipios con estructura débil a moderada (silueta 0,26). El grupo de «frentes de mayor pérdida» tiene 39 municipios (3,5 %) y concentra el 38 % de la pérdida media anual; 85 % de sus municipio-años son Alta.
- En los comentarios, quienes nombran un responsable apuntan sobre todo al gobierno y las autoridades (21 de 117 comentarios); la ganadería, la coca y los grupos armados y la minería aparecen en pocos (6, 8 y 5).

Coincidencias y diferencias entre análisis

- **Coinciden** el modelo supervisado y el clustering en que la magnitud y la persistencia de la pérdida ordenan a los municipios: el grupo de mayor pérdida es también el que casi siempre es Alta.
- **Difieren** en el alcance: el clustering muestra perfiles estables en el tiempo y el modelo solo confirma que lo pasado se repite; ninguno explica por qué.
- **Datos y comentarios.** Los datos muestran las mayores pérdidas en municipios del Caquetá, Meta y Guaviare, y un comentario desde el Caquetá las atribuye a la siembra de pastos para ganado; es un ejemplo entre 6 comentarios que nombran la ganadería, no evidencia suficiente. La coca y la minería ilegal, citadas en los comentarios, no se pueden contrastar con este dataset: su causa dominante solo distingue agricultura permanente y migratoria, silvicultura, minería y otras materias primas, urbanización, incendios y otras alteraciones naturales.

Hipótesis que requieren validación adicional

- Que el modelo aporte algo más que la persistencia con otras variables (distancia a vías, cultivos de coca, minería titulada, títulos mineros, cambios de política) y con ubicación municipal real.
- Que los municipios del grupo 1 sigan perdiendo bosque al ritmo reciente: el clustering describe 2004–2024 y no proyecta.

- Que lo que dicen los comentarios refleje la percepción de la población: con 117 comentarios de 3 videos (22 % de uso escolar) no se puede afirmar.
- Que la caída del recall en 2023 se deba a un cambio de comportamiento: no se verificó.

Decisiones que podrían apoyarse

- Priorizar el monitoreo en el grupo 1 y en los municipios que superaron el umbral el año anterior: son quienes más probablemente vuelvan a superarlo.
- Para alertar con el año de antelación, basta una regla simple como la de persistencia; un modelo complejo no aporta más con estos datos.
- Antes de usar el modelo para focalizar recursos, enriquecerlo con datos municipales verificables y con información de campo.

8. Limitaciones

- Los datos heredan los límites de las etapas anteriores: área redondeada a hectárea entera, focos de calor solo en 2012–2022 y cobertura de MapBiomas parcial.
- La latitud y la longitud del dataset son las del departamento en la mayoría de los registros, por eso no hay mapa municipal ni se puede evaluar el efecto espacial fino.
- La clase Alta depende de un umbral escogido (percentil 75 de 2004–2018); otro umbral cambia el problema.
- Las cifras en Python son una verificación; las de Orange (Test and Score, Silhouette, LDA) prevalecen.
- El clustering tiene estructura débil a moderada y resume 21 años en un renglón por municipio.
- Los comentarios (117, de 3 videos) no son representativos: el 22 % es uso escolar, hay comentarios de otros países, no se leyeron las respuestas y el orden por relevancia favorece lo más votado.

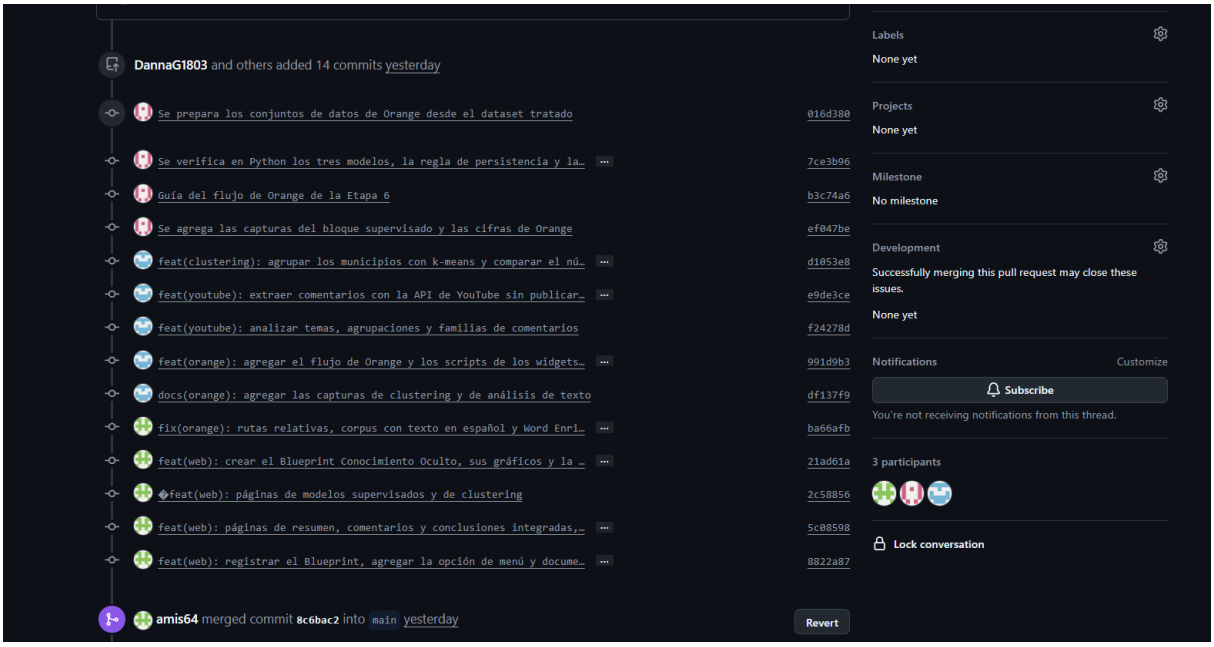
9. Evidencias del Trabajo en el Repositorio

El trabajo se integra en la rama *etapa-6-conocimiento-oculto* mediante un *pull request* por integrante, con tres o cuatro commits cada uno (el mínimo exigido es tres). El repositorio incluye el flujo de Orange (conocimiento_oculto/conocimiento_oculto.ows y orange_scripts/), la preparación de datos, el código de extracción de comentarios, la verificación en Python y

los archivos para reproducir el trabajo; la clave de la API y los comentarios crudos no se publican.

Integrante	Commit
Danna	feat(datos): preparar los conjuntos de datos de Orange desde el dataset tratado
Danna	feat(supervisado): verificar en Python los tres modelos, la regla de persistencia y las pruebas de sensibilidad
Danna	docs(orange): guía del flujo de Orange de la Etapa 6
Nicolás	feat(clustering): agrupar los municipios con k-means y comparar el número de grupos
Amy	feat(web): crear el Blueprint Conocimiento Oculto, sus gráficos y la configuración de enlaces
Nicolás	feat(youtube): extraer comentarios con la API de YouTube sin publicar la clave
Amy	feat(web): páginas de modelos supervisados y de clustering
Nicolás	feat(youtube): analizar temas, agrupaciones y familias de comentarios
Amy	feat(web): páginas de resumen, comentarios y conclusiones integradas, con estilos
Nicolás	feat(orange): agregar el flujo de Orange y los scripts de los widgets Python Script
Amy	feat(web): registrar el Blueprint, agregar la opción de menú y documentar la Etapa 6

Pull request	Rama de origen	Contenido
1	danna-datos-supervisado → etapa-6-conocimiento-oculto	Preparación de datos, modelos supervisados y guía del flujo de Orange
2	nicolas-clustering-youtube → etapa-6-conocimiento-oculto	Clustering, extracción, limpieza y análisis de comentarios, flujo de Orange
3	amy-flask-oculto → etapa-6-conocimiento-oculto	Sección Flask Conocimiento Oculto



10. Referencias y Enlaces de Acceso a los Productos Entregados

Recurso	Enlace
Repositorio del proyecto (GitHub)	https://github.com/amis64/Deforestacion
Aplicación Flask publicada · sección Conocimiento Oculto	https://deforestacion-sco2.onrender.com/conocimiento-oculto/
Video de sustentación (máx. 10 min)	https://youtu.be/sCCgz9RY5uc

Referencias

- Orange Data Mining: orangedatamining.com (Test and Score, k-Means, Preprocess Text, Topic Modelling).
- YouTube Data API v3: developers.google.com/youtube/v3 (commentThreads.list, search.list, videos.list).
- Global Forest Watch (pérdida de cobertura arbórea): globalforestwatch.org.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830 (verificación en Python).

- Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.